

Departamento de Tecnologías de la Información

Escuela Politécnica Superior “La Rábida”

UNIVERSIDAD DE HUELVA



AsGeRe: ASISTENTE DE GENERACIÓN DE RESÚMENES PARA TEXTOS BIOMÉDICOS

José María Bermúdez Peinado

Huelva, Julio 2010

**AsGeRe:
ASISTENTE DE GENERACIÓN
DE RESÚMENES PARA
TEXTOS BIOMÉDICOS**

José María Bermúdez Peinado

Proyecto fin de carrera propuesto
como requisito parcial para la obtención del título de:

INGENIERO INFORMÁTICO

Dirigido por:

Manuel Jesús Maña López

Manuel de la Villa Cordero

A mi novia Ana.

A mi sobrino Daniel.

A mis padres Pedro y Loli, y a mi hermano Perico.

Agradecimientos

Algo con lo que sueña todo el que comienza un proyecto fin de carrera, una tesina o una tesis, supongo que es llegar a escribir los agradecimientos, puesto que aunque sea el primero de los apartados de la documentación, es el último que se escribe, cuando se ha finalizado el trabajo al completo. Y por fin, llegó este momento para mí.

Quería comenzar los agradecimientos dándome las gracias a mí mismo, puede sonar egoísta, pero gracias por demostrarme que soy capaz, que por muchas piedras en el camino, por muchas caídas, he conseguido levantarme, continuar y llegar hasta el final. ¡Gracias!

Lo siguiente es agradecer a la persona que durante todo este tiempo ha sido mi sombra, Ana, le era imposible ayudarme a escribir código, a analizar requisitos o a documentar, pero lo ha solventado apoyándome día tras día en esta dura travesía, a veces de cerca, a veces de lejos, pero sabemos que este proyecto es obra de los dos. ¡Gracias editora!

Además, dar las gracias a mi padre Pedro, por comprar ese MSX cuando era niño y todos los ordenadores que hemos tenido en casa. Desde esos días y noches que pasábamos programando líneas y círculos en el MSX

supe que mi futuro transcurriría delante de un ordenador. Mi padre ha sido mi informático número uno. Y gracias por pagar mis primeros años de carrera.

A mi madre Loli por todas las veces que me ha preguntado por mis exámenes y sobre todo por lo bien que me cuida cuando estoy malito.

A mi hermano Perico sobre todo por su ayuda en darle un tono de color a la aplicación, a él le debo ese bonito icono y la portada de este libro. Además por ser el primero en aguantar la presentación en público de mi aplicación, esa tarde le vi hasta interesado. Y a su mujer Rocío, mi cuñada, que siempre me recuerda que *“ya va siendo hora que acabes los estudios”*.

A mi sobrino Daniel, que aunque no me da ánimos porque aún no sabe hablar, sí que me ha ayudado a distraerme en esas largas tardes de trabajo frente al ordenador. Es verdad que además de distraerme me molestaba muchas veces, pero siempre eran bien recibidas esas interrupciones.

A mis sobrinas Alba y Elena, que no hay día que pase que no me pregunten *“¿has terminado ya el proyecto Tito?”*, pues a partir de hoy sólo os permito una pregunta más, y la respuesta será un rotundo sí.

A mi titi Pilí que ha encuadernado este maravilloso ejemplar, mi tía Carmen, a Curro y a mi prima Marilena, ya terminé prima, ya sé que llevo mucho tiempo y dinero perdido, pero ya terminé.

A mi abuela María que siempre me dice *“tu estudia, tu estudia”* sin darse cuenta de la edad que tengo, y a mi abuelo Eufasio.

Agradecer a esos amigos que incansables me preguntan casi a diario *“¿cuánto te queda?, ¿has terminado ya?”*. Gracias Jose, Javi, Wichi, Simón, Flor, porque estáis ahí cuando verdaderamente se os necesita.

Tras recordar a toda la familia y a los amigos, es imposible olvidarse de todos esos compañeros de carrera, o de fatigas como dirían algunos, la gente que comenzó conmigo en este mundo allá por el 2.000 en la ingeniería técnica Fernando, Joaquín, Rafa, Iván, Javi, Juan Antonio, Adri, Luis, Pablo Miguel, Diego, Campos, Migue, Abdul, Pepe, Fran, Gonzalo, Víctor, Raúl, Ezequiel, Jaime, Ismael, Álvaro, Cinta, Nuria, Nico y muchos otros, porque al empezar, éramos muchos. Los compañeros de la superior Migue, Juanma, Portero, Noa, Pablo, Agu, Nico y Álvaro, muchos seguimos en el Máster. Todos y cada uno de ellos, han tenido un momento especial en mi carrera y en mi vida universitaria, momentos que no se olvidan, pero sobre todo, se han convertido en amigos.

Pero quiero hacer una mención especial a esas personas que me acompañaron en esas jornadas maratónicas de estudio los días previos a las entregas de prácticas en mi casa o en las suyas, desayunando, almorzando, merendando y cenando juntos, pero también trabajando y lo mejor de todo divirtiéndonos, gracias Marcos, Leno, Josele y Fernandele. Siempre recordaré la noche en la terraza de Marcos, desde ese día, quiero comprar el solar de al lado de su casa, esa paz y tranquilidad que respiré en uno de los descansos durante la noche, me marcó. Gracias y me alegro de conocerlos y tenerlos como amigos.

Otra parte muy importante de la carrera y que no puedo olvidar, son los profesores. Unos catalogados por buenos, malos, mejores o peores, pero todos con ganas de enseñar, ayudar y transmitir sus conocimientos. Juanma, Gonzalo, Tomás, Javier Aroba, Jose Luis Alvarez, Jacinto Mata, Antonio Peregrín, Jose Manuel Martín, Francisco Moreno, Victoria Pachón, Carpio, Iñaki, Pablo Palacios, Nieves, Manuel Pedro, Pedro Abad, Joaquin Redondo, Rafael Lopez de Ahumada, Teresa Santos, Nacho Lopez, Manuel Gegúndez, Isabel, Manuel Maestre, Cristóbal... gracias a todos.

Pero hablando de profesores, quiero agradecer enormemente a los que han estado a las duras y a las maduras este último año, con esos buenos ratos en las reuniones del despacho, y alguno que otro malo también, con esos cientos de correos intercambiados y de llamadas por teléfono y sobre todo, por la ayuda ofrecida, el interés mostrado y la paciencia, mucha paciencia, gracias a ellos, este trabajo es una realidad. Gracias, a *“Los Manolos”*, gracias Manolo Maña, gracias Manolo de la Villa... y os recuerdo, que aún no os habéis librado de mí.

A todos, ¡Gracias!

Resumen

Presentamos en esta memoria AsGeRe, una aplicación que da soporte a la generación de resúmenes manuales extractivos, centrada en el ámbito biomédico. Estos resúmenes se denominan Gold Standard y son necesarios en el proceso de evaluación de los sistemas automáticos de generación de resúmenes al establecer una referencia. Los resúmenes automáticos son un reto de gran interés para la comunidad científica como mecanismo de recuperación y acceso a la información. En el ámbito biomédico los resúmenes son de especial utilidad para los médicos, debido por un lado a la sobrecarga de información existente y por otro a la necesidad de respuestas rápidas en sus consultas, p.ej., a pie de cama. La aplicación es capaz de preprocesar el texto, detectar los conceptos biomédicos incluidos, obtener el idioma, dividir el texto en frases. El usuario podrá ir seleccionando las frases que formarán su resumen para posteriormente guardarlo en la base de datos. Basándonos en el trabajo de Reeve, se muestra la distribución de frecuencia de los conceptos que aparecen, como ayuda a la creación del resumen.

Palabras claves: resumen automático, conceptos biomédicos, UMLS, frecuencia de conceptos

Abstract

We present in this report AsGeRe, an application that supports the manual extractive summarization, focusing on the biomedical field. These summaries are called Gold Standard and are necessary in the evaluation process of automatic summaries generation systems to establish a benchmark. Automatic summarization is a challenge of great interest to the scientific community as a mechanism for retrieval and access to information. In the biomedical field, summaries are especially useful for doctors, due to overloading of existing information and to the need for quick answers to their questions, e.g., at bedside. The application is able to preprocess the text, identify biomedical concepts included, identify the language, divide the text into sentences. The user could select the phrases that will form the summary, saving it for later access in a database. Based on work by Reeve, the system shows the frequency distribution of the concepts that appear, as support for the creation of the summary.

Keywords: automatic summarization, biomedical concepts, UMLS, concept frequency

Tabla de contenidos

1. INTRODUCCIÓN.....	1
2. DESCRIPCIÓN DEL PROBLEMA	7
2.1. La importancia de los resúmenes	7
2.2. Parámetros para la elaboración de resúmenes	8
2.2.1. Factores de entrada.....	8
2.2.2. Factores de propósito.....	9
2.2.3. Factores de salida	10
2.3. Generación automática de resúmenes	10
2.3.1. El enfoque extractivo	11
2.3.2. El enfoque abstractivo	13
2.4. Importancia del Gold Standard en la evaluación	14
2.5. Dominio Biomédico: Particularización del problema.....	16
2.6. Recursos en el ámbito Biomédico.....	17
2.6.1. UMLS®	18
2.6.2. MetaMap	22
2.6.3. MetaMap Transfer.....	23

2.6.4. BioMed Central	23
2.7. Importancia de la distribución de conceptos en el resumen	25
3. OBJETIVOS DEL SISTEMA	27
4. HERRAMIENTAS UTILIZADAS	33
4.1. Entorno de desarrollo	33
4.1.1. Eclipse	34
4.1.2. NetBeans	34
4.2. Extracción de texto	35
4.2.1. JDOM	35
4.2.2. Apache PDFBox	36
4.2.3. URL de la página web BioMed Central	37
4.2.4. RTFEditorKit	38
4.2.5. Jakarta POI	38
4.3. Detector de idioma	38
4.3.1. Google-API-translate-java	39
4.3.2. JLangDetect	39
4.3.3. Java Text Categorizing Library	40
4.4. Detector de frases	41
4.4.1. MetaMap	41
4.4.2. OpenNLP Tools	42
4.5. Obtener conceptos UMLS®	43
4.5.1. MMTx	43
4.5.2. MetaMap Java API	43
4.5.3. Servidor MetaMap	44

4.6. Base de datos	44
4.6.1. MySQL.....	45
4.6.2. Servidor Synology DS-207	45
5. MODELO DE REQUISITOS	47
5.1. Requisitos de información.....	47
5.2. Requisitos funcionales	49
5.2.1. Definición de actores	49
5.2.2. Diagramas de casos de uso	50
5.2.3. Casos de uso del sistema.....	51
5.3. Requisitos no funcionales y/o técnicos	58
5.4. Prototipo de la aplicación	59
5.5. Estimación de costes	60
6. MODELO DE DISEÑO	61
6.1. Diagrama de clases	61
6.2. Clases	63
6.2.1. Paquete data.....	63
6.2.2. Paquete extractText	63
6.2.3. Paquete log	64
6.2.4. Paquete metamap	64
6.2.5. Paquete modelo	65
6.2.6. Paquete vista	66
6.2.7. Paquete tests.....	66
6.3. Capa de acceso a datos	66
6.3.1. Tabla de usuarios.....	66

6.3.2. Tabla de documentos.....	67
6.3.3. Tabla de resúmenes	68
7. DESPLIEGUE DEL SISTEMA	69
7.1. Diagrama de despliegue	69
7.2. Arquitectura del sistema.....	70
8. MANUAL DEL USUARIO	71
8.1. Identificación de usuario	71
8.2. Interfaz	72
8.3. Cargar/Abrir documento.....	73
8.3.1. Cargar desde la base de datos.....	74
8.3.2. Abrir archivo.....	75
8.3.3. Abrir página web	76
8.3.4. Pegar Texto	77
8.4. XML.....	77
8.5. PDF	78
8.6. Documento cargado.....	79
8.7. Generar resumen	80
8.8. Ayudas del sistema	81
8.8.1. Estadísticas	81
8.8.2. Listas de conceptos	82
8.8.3. Barra de estado	82
8.9. Administrador del sistema	83
8.9.1. Sequel Pro	83

9. CONCLUSIONES Y TRABAJOS FUTUROS	87
9.1. Conclusiones.....	87
9.2. Trabajos futuros	89
ANEXO I: INSTALACIÓN DE METAMAP	91
ANEXO II: CÓDIGO FUENTE.....	97
REFERENCIAS	99
BIBLIOGRAFÍA.....	103

1. Introducción

Acabo de salir de una reunión con los directores de la empresa, donde he presentado el importantísimo proyecto preparado durante meses, me acabo de quitar un gran peso de encima. Ha salido todo genial y necesito contárselo a Ana, voy a llamarla... Pero al encender el móvil veo que tengo un nuevo mensaje en el buzón de voz:

- Buzón de voz, tienes un mensaje nuevo. Mensaje 1, recibido a las 12 horas 34 minutos... piiiiiiiiii
- ¡Hola cariño!, ¿aún no has terminado la reunión?, espero que todo te vaya fenomenal, no lo dudo, has puesto mucho empeño. Y como te lo mereces, he avisado de manera urgente a toda la gente para cenar a las 21:30 y después salir a celebrarlo... te espero en casa, no llegues tarde... un beso.

Es una situación cotidiana, pero, ¿no sería más útil que el buzón de voz de nuestra compañía telefónica nos diera la opción de poder leer la transcripción de los mensajes de voz de manera escrita?, ¿y si encima nos la proporcionara de manera resumida?.

- Mensaje 1 (Ana): he avisado de manera urgente a toda la gente para cenar a las 21:30

Solamente los datos importantes, ya tendremos tiempo de escuchar el mensaje completo... o no. ¿Es cierto que sueñas con esto?. Por fin nos libraremos de escuchar el mensaje largo y extendido que ha dejado nuestro jefe, amigo, pareja... en el buzón de voz. Al grano, rápido y eficaz...

Es un ejemplo de la situación actual en la que vivimos, en el siglo XXI, en la era de la información, era de la sobrecarga informativa ¹, tenemos a golpe de ratón una enorme cantidad de documentos electrónicos, y crecen de manera exponencial a razón de un 30% anual. Pero tenemos el mismo problema que en las eras y siglos anteriores, y por supuesto en las venideras, el tiempo, nuestro tiempo, sigue siendo un recurso muy valioso y limitado.

Internet ha pasado en pocos años de ser un herramienta exclusiva de unas pocas universidades y organizaciones a introducirse en la mayoría de los hogares. Los avances tecnológicos en la actualidad hacen que el almacenamiento y acceso a los recursos de Internet no sea un problema, por lo que en la actualidad la investigación se centran en mejorar los sistemas de búsqueda, recuperación y extracción de información: *“no está mejor informado quien más datos posee, sino quien dispone de mejores medios para obtener exclusivamente los datos que necesita y asimilarlos (digerirlos)”* (Climent, 2001).

Si nos centramos en el ámbito biomédico, el problema se acentúa. La información en este campo la podemos encontrar en infinidad de formatos: artículos científicos, bases de datos de resúmenes, bases de datos estructuradas o semiestructuradas, servicios web, webs de documentos, historia clínica de pacientes... (Afantenos et al., 2005). Además gran parte de los resultados de la investigación biomédica se encuentra en formato libre (no estructurado) que se acumulan en grandes bases de datos en línea, podemos

¹ Sobrecarga informativa (wikipedia) http://es.wikipedia.org/wiki/Sobrecarga_informativa

concluir que el proceso de reducción de los resúmenes automáticos es especialmente útil en el ámbito biomédico.

Por otra parte, las investigaciones en el campo biomédico están generando cantidad de recursos digitales. Un ejemplo, MEDLINE² (Medical Literature Analysis and Retrieval System Online), es la principal base de datos bibliográfica biomédica, producida por la NLM³ (National Library of Medicine, Biblioteca Nacional de Medicina de los EE.UU.), acumula más de 16 millones de referencias a artículos y creciendo por día.

Podemos asegurar que es necesaria la investigación en la obtención de mecanismos que faciliten la búsqueda, comprensión y utilización de esta ingente cantidad de información. La obtención, el filtrado, la clasificación y la extracción de información, en sus dimensiones mono y multilingüe, son ámbitos prioritarios de la investigación en el campo de la tecnología lingüística. En definitiva, necesitamos herramientas que nos generen resúmenes automáticamente.

El creciente interés por el desarrollo de sistemas de apoyo al acceso y tratamiento de este tipo de información, ha contribuido a la formación de una amplia comunidad de investigadores y al nacimiento de una importante cantidad de proyectos. En España, el número de investigaciones en este campo se ha multiplicado en los últimos años. Se buscan herramientas que ayuden a la creación de resúmenes de manera autónoma.

Tenemos otro dato, el 92% de los documentos de MEDLINE contienen un *abstract* creado por el autor del documento, y podemos preguntarnos, ¿por qué dicho *abstract* no es válido como resumen del documento?. Pues existen

² MEDLINE. <http://www.nlm.nih.gov/pubs/factsheets/medline.html>

³ NLM. (National Library of Medicine). <http://www.nlm.nih.gov/about/index.html>

varias razones que justifican la generación un resumen automático del texto (Cohen et al., 2005):

1. No existe un resumen ideal. El resumen ideal depende de la necesidad o interés de cada usuario. Para el autor, el *abstract* es su resumen ideal.
2. El *abstract* podría estar perdiendo información del texto completo o no haber sido generado por el propio autor (Kostoff et al., 2004).
3. Resúmenes a medida pueden ser muy útiles en sistemas de búsqueda de respuestas (*question-answering*) que proporcionan información personalizada.
4. El uso de generadores de resúmenes automáticos o semiautomáticos puede permitir escalar el número de textos publicados que se puedan evaluar, permitiendo que grandes bibliotecas o colecciones de documentos fueran tratados, algo inasumible con recursos humanos.
5. En la generación de resúmenes multidocumento, se agrupan los documentos por similitud, elemento que puede no ser discernido fácilmente de sólo un *abstract*.

Ya tenemos razones suficientes para generar un resumen automático, y tenemos una máquina que nos genera un resumen a partir de un documento. Ahora se nos presenta otro problema, ¿cómo sabemos que un resumen generado automáticamente es bueno?, ¿puede llegar a ser tan bueno como el que generaría una persona?. Entendemos por bueno a que es capaz de recoger los puntos importantes y relevantes del documento. Para ello necesitamos poder evaluar el resumen obtenido de manera automática. Toda evaluación consiste en la comparación con un patrón que a priori sabemos que es bueno, por ejemplo el generado por un ser humano, es bueno. Pues este patrón es lo que conocemos por *Gold Standard*. Y como lo que queremos es que los resúmenes generados automáticamente sean lo más parecido a los que generaría un humano, nuestro *Gold Standard* debe ser construido en un

principio, por un humano o un conjunto de humanos, preferiblemente especialistas en la materia.

La creación de un *Gold Standard* puede llegar a ser un trabajo tedioso, sobre todo si tenemos en cuenta que para una herramienta de creación de resúmenes automáticos, deberemos generar un *Gold Standard* a partir de una gran cantidad de documentos, y que para cada documento lo ideal es tener el máximo número de patrones a ser posibles generados por distintos participantes.

Llegado a este punto, todo lo expuesto hasta ahora, justifica la realización de este proyecto fin de carrera y de aportar algo a la comunidad investigadora. Se trata de la creación de una herramienta que asista al humano a la generación de un *Gold Standard*. Además nos centraremos en el campo biomédico, por el auge de las investigaciones en dicha rama.

El presente trabajo se centra en la detección de las oraciones y conceptos médicos que componen un documento que se muestra en pantalla. Dichas frases se podrán ir seleccionando para generar el resumen. En todo momento se mostrará una serie de estadísticas y la distribución de frecuencia de los conceptos tanto en el documento como en el resumen, que aportará una ayuda extra al usuario para la creación de su resumen. El sistema tiene un detector automático de idioma, ya que nuestra aplicación es válida para documentos tanto en castellano como inglés. Documentos y resúmenes se almacenarán en una base de datos que nos agilizará el uso de la aplicación y la generación del *Gold Standard* final.

2. Descripción del problema

2.1. La importancia de los resúmenes

Podemos definir resumen, como la reducción a términos breves y precisos del contenido más importante y relevante de un asunto o materia, sin producir ninguna modificación de dicho contenido, con el beneficio de la reducción en el tiempo para asimilar el contenido.

Podemos destacar que de los resúmenes hacemos uso a diario, en ocasiones sin darnos cuenta, como por ejemplo, cuando leemos el título y entrada de una noticia en un periódico, nos ayudará a seguir leyendo o descartarla si no nos interesa. O cuando al comprar un libro miramos el texto en la contraportada, si nos atrae, es un buen síntoma para adquirirlo. O frente a la televisión, al ver los titulares del comienzo de un informativo, en el caso de que nos interesen no cambiaremos de canal. Y como ejemplo principal, cuando necesitamos buscar información en varios textos científicos para cierta temática, podemos comenzar leyendo el *abstract* de cada uno, y si trata sobre el tema que nos interesa y del que necesitamos profundizar en la información,

continuaremos en la lectura del documento al completo, en caso contrario, lo descartamos.

Vemos, que podemos obtener un resumen a través de muy diversos medios, pero que en todos los casos nos ayudan a decidir si seguir recibiendo información o prescindir en caso de que no nos interese, sin tener que perder un tiempo excesivo en asimilar la noticia, el libro, informativo o documento al completo.

2.2. Parámetros para la elaboración de resúmenes

A la hora de generar el resumen de un documento, tenemos que tener en cuenta una serie de factores (Sparck-Jones, 1999), que podemos dividir en *factores de entrada*, *factores de propósito* y *factores de salida*:

2.2.1. Factores de entrada

Conocidos como *input*, se trata de las características que posee el texto fuente con el que vamos a trabajar. A su vez, se dividen en *forma*, *especialidad* y *alcance*.

Forma

La forma del documento se define por su *estructura*, *escala*, *medio* y *género*:

- *estructura*: se refiere tanto a la organización explícita y generalmente marcada en el texto (secciones o apartados, método, datos, etc.) como a la organización que se encuentra en el discurso.

- *escala*: se refiere al tamaño del resumen que vamos a generar, e influye tanto en el factor de compresión como en la transformación de contenido necesaria.
- *medio*: se refiere al tipo de lenguaje utilizado (telegráfico, prosa, periodístico, etc.)
- *género*: se refiere al estilo literario del documento (descriptivo, narrativo...)

Especialidad

Hace referencia al nivel de especialización del texto. Según la especialidad, un texto puede considerarse como *ordinario*, *especializado* o *restringido*.

Alcance

Indica al número de documentos que intervienen en la elaboración del resumen y al grado en que estos se relacionan entre sí.

2.2.2. Factores de propósito

También conocidos como *purpose*, recogen la intención con la que se realiza el resumen. Son los más importantes, pero también los más ignorados. Podemos distinguir:

- *situación*: pretende discernir entre la generación de resúmenes en un contexto conocido a priori y en un contexto variable.
- *audiencia*: se refiere a los conocimientos, la competencia lingüística, formación... de los lectores a los que va dirigido.
- *función*: puede ser la de sustituir al documento original, ayudar a recordar el contenido, pre-visualización del documento...

2.2.3. Factores de salida

Llamados también *output*, y son las características, en forma y contenido, que ha de cumplir el resumen generado:

- *extensión*: grado en que el resumen ha de capturar el contenido de la fuente. Pueden ser resúmenes totales o parciales.
- *formato*: el resumen puede presentarse como un texto continuo o como una sucesión de apartados o secciones.
- *estilo*: un resumen puede ser informativo, indicativo, crítico o agregativo.

Con el análisis de todos los factores a tener en cuenta a la hora de la creación de un resumen, se antoja complicado la idea de obtener una herramienta capaz de generar resúmenes automáticamente aplicando solamente una técnica y que estos sean genéricos e independientes del contexto. Por lo que las investigaciones se centran en cómo se deben analizar los factores anteriores para la interpretación del texto y la generación del resumen.

2.3. Generación automática de resúmenes

Por generación automática de resúmenes de texto entendemos el proceso por el cual se identifica la información sustancial proveniente de una fuente para producir una versión abreviada destinada a un usuario particular y una tarea.

La finalidad de los resúmenes es facilitar y acelerar la identificación de los temas de interés entre una gran cantidad de documentos. Con el objetivo final de evitar el tiempo de lectura que se necesitaría para localizar la información que deseamos en determinado momento. Pero nos encontramos

con un problema, y es que la elaboración de resúmenes consume abundante recursos humanos, entonces, ¿por qué no lo hace una máquina?. Debemos aprovechar las ventajas que ofrecen las tecnologías para sustituir el coste humano. Llegamos a la conclusión, de que tenemos que enseñar a las máquinas a generar resúmenes.

Centrándonos en la generación de resúmenes automáticos de texto, nos encontramos con una serie de trabajos previos que nos indican que existen de manera general dos enfoques: el *enfoque extractivo* y el *enfoque abstractivo*. Aunque típicamente los humanos realizan resúmenes mediante abstracción, la mayor parte de la investigación hoy día sigue basándose en el enfoque extractivo, y en general, los resultados alcanzados son comparativamente mejores. Veamos detenidamente ambos enfoques:

2.3.1. El enfoque extractivo

El enfoque extractivo consiste en seleccionar y extraer frases o partes de ella del texto fuente para generar nuestro resumen. Se realiza un análisis superficial del texto, y no va más allá del nivel sintáctico.

La mayor ventaja que tiene este enfoque es que resulta muy robusto y fácilmente aplicable a contextos de propósito general, ya que posee una independencia muy alta con respecto al dominio e incluso al género de los documentos.

Pero este enfoque presenta algunos problemas importantes, derivados de la no consideración de la estructura semántica del documento y de las relaciones existentes entre los términos que lo componen (sinonimia, hiperonimia, homonimia, coocurrencias o asociaciones semánticas).

Los sistemas que se basan en extracción típicamente siguen una arquitectura estructurada en dos procesos: *análisis* y *síntesis* (Figura 2.1) (Hahn y Many, 2000).




Figura 2.1. Arquitectura de un sistema de enfoque extractivo. Basado en Hahn y Many, 2000.

La mayor parte del trabajo se realiza durante la **fase de análisis**. Se procesa cada unidad del documento fuente (frase, oración o párrafo) y se le calcula su puntuación o peso. Para ello, se computan un conjunto de características para cada unidad, se normalizan y se suman. Las métricas empleadas se pueden clasificar en:

- *estadísticas*, que calculan la importancia de una unidad en función de la frecuencia de aparición de ciertos términos relevantes;
- *posicionales*, que tienen en cuenta la posición que ocupa la unidad en el documento fuente, y
- *lingüísticas*, que buscan ciertas expresiones o palabras indicativas.

En la **fase de síntesis** se extraen las unidades mejor puntuadas y se concatenan en el mismo orden que en el texto original, generando así el resumen. Adicionalmente, algunos trabajos incluyen mejoras en la coherencia mediante la eliminación de redundancia y algún otro procesamiento.

Las heurísticas más utilizadas para la selección de unidades claves en el documento fuente son (Paice, 1990): frecuencia de palabras, palabras claves en el título, criterios posicionales, palabras claves y frases indicadoras.

2.3.2. El enfoque abstractivo

El enfoque abstractivo suele englobar técnicas de procesamiento del lenguaje natural, más complejo pues necesita un conocimiento léxico, gramatical y sintáctico del dominio, para modelar semánticamente el conocimiento y a partir de éste ser capaz de generar un resumen. Por tanto, el resumen resultante, a diferencia de lo que ocurre cuando se utilizan técnicas de extracción, puede contener texto que no aparece explícitamente en el documento fuente.




Figura 2.2. Arquitectura de un sistema de enfoque abstractivo. Basado en Hahn y Many, 2000.

La arquitectura de este tipo de sistemas es algo más compleja que los sistemas de extracción, estructurándose en tres fases (Figura 2.2) (Hahn y Many, 2000).

En la **fase de análisis**, se construye una representación semántica del contenido del texto. Esta representación puede construirse, por ejemplo, mediante la utilización de predicados lógicos, redes semánticas o conjuntos de plantillas.

En la **fase de transformación**, se realizan diversas operaciones que permiten obtener una representación semántica condensada del texto fuente. Así, por ejemplo, se puede eliminar la información redundante o irrelevante, generalizar la información mediante la utilización de taxonomías o añadir información procedente de otros textos relacionados y almacenada en la base de conocimiento textual.

Finalmente, durante la **fase de síntesis**, se utiliza la representación semántica ya condensada para generar un resumen en lenguaje natural.

2.4. Importancia del Gold Standard en la evaluación

Pero sin lugar a dudas, cuando hablamos de generación automática de resúmenes, la primera pregunta que nos viene a la cabeza es, “¿son buenos?, ¿son tan buenos como los de un humano?”. Y la respuesta, es otra pregunta, “¿qué es un buen resumen?”.

Cualquier tipo de investigación tiene como tarea obligatoria la evaluación de los resultados obtenidos. Para los resúmenes automáticos de textos la evaluación de los mismos puede realizarse comparándolos con otros que actúen de patrones, unos resúmenes ideales. Este conjunto de patrones es lo que conocemos por *Gold Standard*.

Y la pregunta es, ¿cómo generamos un *Gold Standard*? Pues si nuestra intención es obtener unos resúmenes buenos, entendiendo por buenos como lo más próximo a los que puedan generar los humanos, tendremos que generar un *Gold Standard* utilizando a personas para confeccionar los resúmenes. Para lo cual se suele pedir a un conjunto de analistas, especialistas en la materia

que realicen resúmenes o extractos de un conjunto de documentos de prueba. El problema consecuente, es el coste del trabajo que debe realizar el humano.

Además, la obtención de un resumen ideal no es una tarea trivial, está demostrado que dado un mismo documento, difícilmente existe acuerdo entre varios analistas sobre cuál es la información que es pertinente seleccionar como resumen. Incluso se ha dado el caso que para un mismo sujeto y sobre un mismo contenido, se han obtenido distintos resultados en pruebas distanciadas en el tiempo.

Tras la obtención del *Gold Standard*, se pueden evaluar los resúmenes obtenidos de manera automática mediante sistemas como ROUGE⁴. Se trata de un sistema que determina automáticamente la calidad de un resumen por comparación con otros ideales, nuestro *Gold Standard*.

ROUGE ha adaptado los métodos de evaluación de los traductores automáticos de texto a la evaluación de resúmenes automáticos. Los métodos más usados para medir la calidad de una traducción son BLEU⁵ y NIST⁶. BLEU se calcula a nivel de frases y mide la precisión de los n-gramas con respecto al conjunto de referencia. Un n-grama es una secuencia de una o más palabras consecutivas. NIST es una variante de BLEU, que otorga mayor peso a los n-gramas menos frecuentes.

Para una mejor evaluación necesitamos un conjunto de resúmenes lo más amplio posible, de ahí la importancia de la herramienta que presentamos, que facilitará el trabajo del humano en la creación del *Gold Standard*.

⁴ ROUGE (Recall-Oriented Understudy for Gisting Evaluation). <http://berouge.com/default.aspx>

⁵ BLEU (Bilingual Evaluation Understudy). <http://en.wikipedia.org/wiki/BLEU>

⁶ NIST (National Institute Standards and Technology). [http://en.wikipedia.org/wiki/NIST_\(metric\)](http://en.wikipedia.org/wiki/NIST_(metric))

2.5. Dominio Biomédico: Particularización del problema

En nuestro caso, centraremos el trabajo en los documentos del dominio biomédico, debido a que la reducción de información a través de resúmenes automáticos es particularmente útil en este campo, donde los médicos están en una búsqueda continua de información en estudios clínicos de prueba.

Un claro ejemplo sería la medicina basada en la evidencia, que ha sido tradicionalmente definida como el uso consciente, explícito y juicioso de la mejor evidencia disponible para la toma de decisiones en el cuidado de nuestros pacientes (Sackett et al., 1996). Es decir, se busca fundamentar la medicina cotidiana sobre bases científicas, buscando la mejor evidencia disponible a nivel mundial para tomar una decisión basándose en el estado actual del conocimiento y no en base a suposiciones o creencias. Por lo tanto, como herramienta básica en la que se asienta esta metodología está la lectura de la literatura biomédica a nivel mundial. Y tratándose de una de las ramas de la ciencia con mayor abundancia de documentación, podemos imaginar la cantidad de literatura existente con la que se puede llegar a trabajar. Veamos algunos datos de MEDLINE:

- más de 16 millones de referencias a artículos,
- se añaden diariamente de 2.000 a 4.000 referencias completas, y
- sólo en 2009 se añadieron más de 712.000.

Hay una clara necesidad de herramientas para los profesionales de este dominio que les proporcione medios de acceso a la información adecuada para sus necesidades y en un tiempo eficiente. Un reciente trabajo cualitativo concluyó que dos de los seis obstáculos para responder a cuestiones clínicas aplicando la evidencia eran: el tiempo requerido para encontrar información, y la dificultad para seleccionar una estrategia óptima de búsqueda (Ely et al., 2002).

Además, contamos con la ventaja de que los artículos biomédicos son publicados con un resumen propio del autor (*abstract*), lo cual nos ayudará en la creación de nuestro *Gold Standard*, puesto que será uno de los resúmenes asociados al documento. Dicho resumen se considera válido por varias razones:

- ha sido creado por el propio autor del documento que conoce los contenidos importantes a incluir,
- porque el autor es un especialista en la materia, y dichos documentos van dirigidos a especialistas como él, y por último
- porque la revista donde se publicará el documento marca unas pautas que especifican los contenidos que debe incluir el resumen de cada apartado del artículo.

2.6. Recursos en el ámbito Biomédico

En los trabajos donde hay un procesamiento del lenguaje natural se necesitan herramientas y recursos que den soporte al proceso. Si además nos encontramos en un dominio específico, el conocimiento del experto ha de encontrarse recogido y plasmado, por ejemplo, en diccionarios que recojan todos los términos y conceptos, así como las posibles relaciones semánticas.

En este trabajo se han usado una serie de herramientas y repositorios dentro del ámbito biomédico, como son: UMLS®, MetaMap y BioMed Central, además veremos otras propuestas que no hemos probado, como es el caso de MMTx.

2.6.1. UMLS®

En 1986, la NLM comenzó a trabajar en el Sistema Unificado de Lenguaje Médico (UMLS®⁷), un proyecto destinado a reducir los obstáculos fundamentales para la aplicación de la informática a la medicina, ayudando a investigadores en la representación del conocimiento, recuperación e integración de información biomédica. Se trata de un sistema que garantiza referencias cruzadas entre más de treinta vocabularios y clasificaciones, proporcionando una estructura de mapeo entre estos vocabularios. También podemos verlo como un diccionario de sinónimos y ontología de conceptos biomédicos.

Lo usaremos para el procesado semántico, donde identificaremos los conceptos y relaciones subyacentes en un texto, se requiere que el texto pueda ser mapeado a una estructura de conocimiento, como la que en el ámbito biomédico proporciona el proyecto UMLS® (Humphreys et al., 1998).

UMLS® está compuesto por el *Meta-tesauro* (Metathesaurus), el *Léxico Especializado* (SPECIALIST Lexicon) y la *Red Semántica* (Semantic Network) (Rindflesh et. al., 2005), vamos a describir brevemente cada uno de estos componentes.

Meta-tesauro

Se trata de una base de datos multilingüe y multipropósito que contiene información sobre conceptos biomédicos y relacionados con la salud pertenecientes a más de 100 vocabularios y terminologías médicas, incluyendo sus diferentes nombres y sus relaciones. Está formado por más de un millón de conceptos semánticos que a su vez se engloban en 135 tipos semánticos relevantes en el ámbito biomédico (y siempre, al menos en uno).

⁷ UMLS®. http://www.nlm.nih.gov/research/umls/about_umls.html

Así, por ejemplo, la entrada “*Arthritis, Juvenile Rheumatoid*” produciría la información jerárquica mostrada en la figura 2.3:




Figura 2.3. Ejemplo del Metatesaurus UMLS®

Léxico especializado

Se trata de una base de datos lexicográfica donde se describen las características sintácticas de términos en inglés de carácter biomédico y general, proporcionando la base para el procesamiento de lenguaje natural en el dominio biomédico. Además de etiquetas con la categoría gramatical (*part of speech*), para cada entrada se incluyen variaciones ortográficas que ocurran, inflexiones en nombres, verbos y adjetivos.

Así por ejemplo, “*Anaesthetic*” produciría las respuestas que muestra la figura 2.4:

```
{base=anesthetic
spelling_variant=anaesthetic
entry=E0330018
cat=noun
variants=reg
variants=uncount }

{base=anesthetic
spelling_variant=anaesthetic
entry=E0330019
cat=adj
variants=inv
position=attrib(3)
position=pred stative },
```

Figura 2.4. Ejemplo del Léxico especializado de UMLS®

La información recogida en la figura 2.4 indica que el término puede aparecer como sustantivo o adjetivo. En caso de ser sustantivo tiene un plural regular, incontable. En caso de ser adjetivo es invariante, puede aparecer en el predicado y es un adj. atributivo.

Red semántica

La red semántica constituye una ontología del más alto nivel de la medicina, compuesta por 135 tipos semánticos asignados a conceptos del meta-tesauro y por 54 tipos de relaciones entre los tipos. Se puede decir, por lo tanto, que los tipos semánticos son los nodos en la red y los enlaces son las relaciones entre ellos.

El enlace principal es la relación de hiponimia o “es un”, que establece la jerarquía entre los tipos de la red. Existe otro grupo de relaciones, agrupadas en cinco categorías principales: *physically_related_to*, *spatially_related_to*, *temporally_related_to*, *functionally_related_to* y *conceptually_related_to*.

Además, los tipos semánticos se clasifican en seis agrupaciones básicas: *organismos*, *estructuras anatómicas*, *funciones biológicas*, *productos químicos*, *eventos*, *objetos físicos* y *conceptos o ideas*, y permiten la categorización semántica de un amplio abanico de terminología en múltiples dominios de especialidad.

En la siguiente figura se muestra un fragmento de la jerarquía conceptual de la Red Semántica UMLS. Las aristas entre nodos no etiquetadas, por defecto recogen relaciones de hiponimia. Así mismo, las asociaciones entre conceptos se heredan por sus nodos especializados.




Figura 2.5. Red asociada al tipo semántico Organism (McCray, 2003)

2.6.2. MetaMap

MetaMap⁸ es una aplicación desarrollada por la NLM, en el marco del *Indexing Initiative System*, para el mapeo de textos biomédicos a conceptos del Meta-tesauro de UMLS®.

MetaMap utiliza un enfoque intensivo en conocimiento, basado en técnicas lingüísticas y de procesamiento de lenguaje natural, haciendo uso de herramientas como el léxico especializado de UMLS®.

Aunque fuera inicialmente concebido como soporte en la recuperación de material bibliográfico de MEDLINE, a partir de peticiones formuladas en inglés, lo cierto es que su utilidad se extiende a la resolución de todo tipo de problemas de recuperación de información, minería de texto, categorización y clasificación, generación de resúmenes o descubrimiento de conocimiento.

Funcionamiento del Algoritmo

El programa MetaMap acepta como entrada el documento que se desea procesar. Seguidamente, para cada oración, ejecuta los siguientes pasos:

1. Se parsea el texto para extraer los sintagmas nominales.
2. Para cada sintagma identificado, se generan una serie de variantes, que consisten en combinaciones de una o varias de las palabras que lo forman, junto con sus variaciones morfológicas inflexionales y derivacionales, abreviaturas, acrónimos y sinónimos.
3. Se obtienen del Meta-tesauro de UMLS los posibles candidatos, extrayendo los términos que contienen alguna de las variantes.
4. Para cada candidato, se utiliza una función de evaluación para calcular una medida de la relevancia del mapeo, y se ordenan los candidatos de mayor a menor.

⁸ MetaMap. <http://metamap.nlm.nih.gov/>

5. Se combinan los candidatos con otras partes no adyacentes del sintagma nominal, se vuelven a calcular las puntuaciones y se seleccionan aquellos candidatos con mayor puntuación, formando un conjunto de “mejores candidatos” para el sintagma original.

El uso de MetaMap en AsGeRe se limita al mapeo de las oraciones del documento a conceptos del meta-tesauro de UMLS®. Para ello se ha optado por usar MetaMap Java API⁹. Previamente tenemos que tener instalado y ejecutándose en nuestro servidor MetaMap al completo.

2.6.3. MetaMap Transfer

MetaMap Transfer ¹⁰ (MMTx), no es más que una versión de MetaMap para Java™. Fue un intento de proporcionar una versión distribuible de MetaMap, pero se ha abandonado en favor de la versión original de Prolog por dos causas:

- porque MetaMap es mucho más rápida que MMTx, y
- porque MMTx producía unos resultados en torno al 20% diferentes a los de MetaMap.

2.6.4. BioMed Central

BioMed Central¹¹ se trata de una editorial independiente dedicada a la publicación de artículos de investigación en los campos de Biología y Medicina. Se basa en una política *open access*, donde todos los artículos son de acceso libre. La política de negocio se fundamenta en cobrar al autor por publicar, en

⁹ MetaMap Java API. http://metamap.nlm.nih.gov/README_javaapi.html

¹⁰ MMTx (MetaMap Transfer). <http://ii-public.nlm.nih.gov/MMTx/>

¹¹ BioMed Central. <http://www.biomedcentral.com/info/>

vez de al lector. Para la publicación, los artículos son sometidos a un proceso de arbitraje según la manera tradicional (*peer review*). Cuando son aprobados, inmediatamente son almacenados de manera permanente en PubMed Central¹² y otros archivos internacionales, desde donde son fácilmente accesibles por toda la comunidad desde Google Académico¹³, Scirus¹⁴ o MEDLINE. Esto permite a los autores que sus publicaciones tengan más posibilidades de ser vistas, leídas y citadas, y garantiza a la comunidad científica un rápido y eficaz acceso de los resultados de investigación actuales.

Actualmente BioMed Central posee una cartera de 207 revistas, incluyendo títulos generales como BMC Biology¹⁵, BMC Medicine¹⁶, y otras revistas especializadas como BMC Bioinformatics¹⁷ o Malaria Journal¹⁸.

Los autores conservarán el copyright de su trabajo, bajo la licencia Creative Commons Attribution¹⁹. Esta licencia permite que los artículos sean libremente descargados desde el sitio web, y que puedan ser utilizados y redistribuidos sin restricciones, siempre y cuando se cite la obra original.

La aplicación AsGeRe está plenamente adaptada a los documentos de BioMed Central, puesto que una vez publicados los artículos en PDF²⁰, pasan una revisión donde son adaptados al tipo de publicación propio de BioMed

¹² PubMed Central (PMC). <http://www.ncbi.nlm.nih.gov/pmc/about/intro.html>

¹³ Google Académico. <http://scholar.google.es/intl/es/scholar/about.html>

¹⁴ Scirus. <http://www.scirus.com/>

¹⁵ BMC Biology. <http://www.biomedcentral.com/bmcbiol/>

¹⁶ BMC Medicine. <http://www.biomedcentral.com/bmcmed/>

¹⁷ BMC Bioinformatics. <http://www.biomedcentral.com/bmcbioinformatics/>

¹⁸ Malaria Journal. <http://www.malariajournal.com/>

¹⁹ Licencia Creative Commons 2.0 genérica. <http://creativecommons.org/licenses/by/2.0/deed.es>

²⁰ PDF (Portable Document Format). <http://es.wikipedia.org/wiki/PDF>

Central, para el cual se genera un fichero XML²¹, con el que la aplicación trabaja perfectamente.

Los ficheros XMLs poseen una estructura propia en la que nos basamos para obtener las características fundamentales del documento para nuestra aplicación, como son el título, el autor o autores, la fecha de publicación y el *abstract*. Además cuando se abre un fichero en PDF que ya ha sido revisado por BioMed Central, la aplicación se encarga de descargar el propio fichero XML accediendo a la página web y haciendo más rápido y fácil el trabajo al usuario.

2.7. Importancia de la distribución de conceptos en el resumen

Reeve propone la frecuencia de aparición de los conceptos como un método para identificar las frases más importantes de un documento (Reeve et al., 2006). Los autores afirman que la distribución de frecuencias de conceptos del resumen que generamos debería parecerse lo máximo posible a la del documento original. Es decir, los modelos de distribución deben ser lo más parecido posible.

La aplicación utiliza MetaMap para obtener los conceptos biomédicos asociados a cada una de las frases del documento, lo que nos permitirá trabajar a nivel de conceptos del dominio, en lugar de términos.

Para mostrar que los conceptos biomédicos también siguen una distribución Zipfiana²², Reeve utilizó un corpus de 24 documentos biomédicos,

²¹ XML (Extensible Markup Language). http://es.wikipedia.org/wiki/Extensible_Markup_Language

²² Ley de Zipf. http://es.wikipedia.org/wiki/Ley_de_Zipf

extrajeron los conceptos de los resúmenes de los autores (*abstract*) y del texto al completo utilizando MMTx, y compararon los modelos distribución de los conceptos en los resúmenes ideales (*abstracts*) y los documentos al completo. Estas distribuciones se muestran en la figura 2.6.




Figura 2.6. Distribución de conceptos con 24 documentos biomédicos (Reeve et al., 2006):
 (a) Distribución de 488 conceptos obtenidos en los abstracts.
 (b) Distribución de 2.317 conceptos obtenidos en los documentos al completo.

Por lo tanto, podemos concluir que una buena herramienta para obtener las frases más importantes de un documento es la frecuencia de distribución de los conceptos. Además, el uso de conceptos puede ser muy útil para la generación de resúmenes personalizados, un sistema donde el usuario pueda seleccionar los conceptos más importantes en el dominio, hace que pueda obtener resúmenes donde esos conceptos tengan mayor peso.

3. Objetivos del sistema

En este capítulo vamos a tratar de describir los objetivos fundamentales que la aplicación debe satisfacer.

AsGeRe tiene como objetivo fundamental la asistencia a la hora de generar un resumen sobre un documento previamente cargado. El usuario tendrá que ir seleccionando las frases que considere más importantes, obteniendo así un resumen extractivo. En todo momento, tendrá como asistencia una serie de estadísticas y una lista con la distribución de frecuencias de los conceptos médicos que aparecen en el documento original y en el resumen. Tras generar el resumen, el usuario puede guardarlo en una base de datos que tendrá como objetivo la posterior generación del *Gold Standard*.

El sistema debe estar escrito completamente en lenguaje **Java**²³, para hacerlo portable a todo tipo de sistemas. Para su implementación se hará uso de la plataforma **NetBeans**²⁴, plataforma que facilita la creación de interfaces usando Java Swing²⁵.

²³ Java™. <http://www.java.com/es/>

²⁴ NetBeans. http://netbeans.org/index_es.html

²⁵ Java Swing. [http://es.wikipedia.org/wiki/Swing_\(biblioteca_gráfica\)](http://es.wikipedia.org/wiki/Swing_(biblioteca_gráfica))

El sistema debe apoyarse en una **base de datos MySQL**²⁶ donde se almacenarán los resúmenes que los usuarios vayan generando. Deberá estar preparado para que la base de datos se implante en un servidor externo.

La base de datos deberá almacenar un **registro de los usuarios** que pueden acceder y hacer uso del sistema, así como contemplar la posibilidad de insertar nuevos usuarios en un futuro. Este registro de usuarios permitirá un acceso restringido a la aplicación para asegurarnos un correcto uso y conocer el autor de cada uno de los resúmenes.

El sistema debe permitir **abrir ficheros de documentos** en varios formatos: PDF, RTF²⁷ y TXT²⁸, además de poder pegar texto directamente o incluso introduciendo la URL de la página web de BioMed Central donde se encuentra el documento. Pero donde la aplicación ofrecerá mejores posibilidades será con **ficheros XML**, debido a que al ser un tipo de fichero etiquetado, nos permitirá obtener información de manera automática.

Una vez cargado el fichero, el sistema debe **extraer el texto** que conforma el documento. En el caso de que se trabaje con un fichero XML, el sistema deberá obtener de manera automática la **información interesante del documento**: título, autores, fecha de publicación y *abstract*. En caso contrario, el sistema mediante el despliegue de una ventana, solicitará al usuario que introduzca esta información de manera manual. Al mostrar el texto en la interfaz, se eliminará todo tipo de información superflua, como imágenes, tablas o bibliografía, así como el *abstract* para que no influya al usuario en la creación de su resumen, dejando sólo el texto del artículo.

²⁶ MySQL. <http://www.mysql.com/about/>

²⁷ RTF (Rich Text Format). http://es.wikipedia.org/wiki/Rich_Text_Format

²⁸ TXT (Texto plano). http://es.wikipedia.org/wiki/Archivo_de_texto

Durante el procesado del documento, el sistema deberá ser capaz de **obtener de manera automática el idioma** en el que está escrito el documento, así como conseguir **dividir el texto en las frases** que lo componen.

La aplicación deberá ser capaz de **obtener los conceptos médicos** asociados a un documento haciendo uso de la herramienta MetaMap. Es importante remarcar esta característica, ya que permitirá a la aplicación **extraer conocimiento a partir de texto plano**.

Además, como se desea la mayor fluidez posible en la utilización de la aplicación, y dado que existe una tardanza considerable en el procesado del documento al obtener el idioma, frases y conceptos médicos asociados, se deberá **almacenar toda la información referente a un documento en la base de datos**. Esto agilizará la carga para comenzar a trabajar, puesto que si ya existe indexado en la base de datos, se obtendrá toda la información directamente desde dicha base de datos, suprimiendo el costoso tiempo de procesado del documento.

Cuando se cargue un documento mediante un fichero, el sistema a partir del título (ya sea obteniéndolo automáticamente, en el caso de un XML o solicitando al usuario que lo introduzca manualmente) debe estar capacitado para **buscar el documento en la base de datos**, y si ya existiera indexado, obtener la información de una manera inmediata, evitando el procesado. En el caso de que no exista en la base de datos, y estemos trabajando con un documento que no es XML, el sistema buscará dicho fichero directamente en la página web de BioMed Central, consiguiendo mayor rapidez y un mejor funcionamiento.

Si el sistema no reconociera el documento con el que estamos trabajando debido a que aún no lo tuviera indexado, deberá procesarlo y obtener todas las características. Por último, se **añadiría automáticamente a la base de datos** para futuros usos, así como su *abstract*, como el primero de los resúmenes asociados al documento.

Llegado a este punto, el sistema debería tener toda la información necesaria para mostrar al usuario en la **interfaz**:

- Por un lado, mostrará el documento dividido en las frases que lo componen (se tratará de una división interna, de forma transparente al usuario).
- Por otro lado, se mostrará el resumen que vaya generando el usuario, seleccionando manualmente las frases desde el cuadro del texto original.
- Además se deberá mostrar un **cuadro con estadísticas**, donde se muestre el número total de frases y palabras que componen el texto y el resumen, y el porcentaje de elementos que componen el resumen con respecto del texto completo.
- Por último, se mostrarán las **listas de los conceptos** asociados al documento original y al resumen que el usuario vaya generando, así como sus frecuencias asociadas.

El cuadro de estadísticas y las listas de conceptos con sus frecuencias asociadas, servirán al usuario de ayuda para una mejor generación del resumen, apoyándose en la similitud de las distribuciones de los conceptos del documento original y del resumen que se va generando, como defiende Reeve (Reeve et al., 2006).

En el caso de documentos escritos en inglés, se obtendrán los conceptos médicos asociados mediante MetaMap, puesto que existe el léxico y el analizador en inglés que MetaMap necesita; sin embargo, para textos en castellano no existen y si usáramos la herramienta a nivel de palabras en vez de a nivel de frase, obtendríamos problemas de desambiguación, por lo tanto, no se podrá usar MetaMap para documentos en castellano. En tal caso, se mostrará una lista de las palabras que forman el documento tras aplicarle un algoritmo de eliminación de palabras vacías (*Stopper*) y un lematizador²⁹ para reducir las palabras a la raíz (*Stemming*³⁰).

²⁹ Un *lematizador* es un programa, basado en diferentes algoritmos, que trabaja sobre un corpus de textos en lenguaje natural y realiza una extracción automática de términos simplificados a su esencia o *lema*.

³⁰ Stemming. <http://es.wikipedia.org/wiki/Stemming>

4. Herramientas utilizadas

En este capítulo mostraremos todas las herramientas, librerías y demás utensilios usados en el sistema, para su correcto funcionamiento. Veremos el entorno de desarrollo elegido, los métodos usados para obtener el texto desde los distintos tipos de ficheros posibles, las posibilidades probadas para detectar el idioma del documento, la solución adoptada para la tarea de división del texto en frases y de obtención de los conceptos UMLS del texto, y por último, hablaremos de la base de datos usada para el almacenamiento de los datos necesarios para el funcionamiento del sistema.

4.1. Entorno de desarrollo

Un entorno de desarrollo integrado (IDE³¹) se trata de una herramienta para que los programadores puedan escribir, compilar, depurar y ejecutar programas. En nuestro caso, el primer objetivo claro era el uso del lenguaje de programación Java™, para conseguir la portabilidad deseada de la aplicación.

Veamos los distintos IDEs que se ha planteado utilizar.

³¹ IDE. http://es.wikipedia.org/wiki/Entorno_de_desarrollo_integrado

4.1.1. Eclipse

Eclipse³² es un IDE de código abierto³³ y multiplataforma. Escrito en Java™, se usa para desarrollar aplicaciones tanto en Java™ como en otros lenguajes como C, C++, Python o PHP, siempre que contemos con las extensiones adecuadas. Ha sido usado para desarrollar IDEs propios de Java™ como *Java Development Toolkit* (JDT³⁴) y el compilador (ECJ) que se entrega como parte de Eclipse.

Desarrollado originalmente por IBM, ahora se encarga del desarrollo la Fundación Eclipse, una organización independiente sin ánimo de lucro que fomenta una comunidad de usuarios de código abierto.

Eclipse fue la primera opción elegida para la creación de la aplicación, pero un punto muy importante de la herramienta es la interfaz, y Eclipse tiene el fallo de que todas las opciones de editor gráfico para Java Swing son de pago, por lo que se descartó esta opción.

4.1.2. NetBeans

NetBeans es un IDE escrito en Java™, pero puede servir para cualquier otro lenguaje de programación. Existe además un número importante de extensiones. Además, es un producto libre y gratuito sin restricciones de uso. El código fuente está disponible para su reutilización. En sus comienzos, fue desarrollado por Sun Microsystems³⁵ en junio de 2000 y actualmente una comunidad de código abierto se encarga de su constante desarrollo.

³² Eclipse. <http://www.eclipse.org/org/>

³³ Código abierto. http://es.wikipedia.org/wiki/Código_abierto

³⁴ JDT. http://en.wikipedia.org/wiki/Java_Development_Kit

³⁵ Sun Microsystems. <http://es.sun.com/aboutsun/company/index.jsp>

En nuestro caso, el punto fuerte de NetBeans en comparación con el IDE Eclipse, es el increíble editor gráfico Swing que proporciona con el propio IDE y de manera totalmente gratuita. Es la opción más versátil para generar la interfaz que necesitamos de una manera rápida, sencilla, eficaz y sobre todo económica.

4.2. Extracción de texto

El sistema, está capacitado para trabajar con ficheros tales como PDF, TXT, RTF, pero especialmente trabaja ficheros de tipo XML. Además es capaz de extraer el fichero XML, si existe, desde una URL de la página web BioMed Central perteneciente a un documento.

4.2.1. JDOM

JDOM³⁶ es una biblioteca de código abierto para acceder, manipular y exportar datos a XML, optimizado para Java™. A pesar de su similitud con DOM³⁷ del consorcio World Wide Web (W3C³⁸), es una alternativa que no está incluida en DOM. La principal diferencia es que mientras que DOM fue creado para ser un lenguaje neutral e inicialmente usado para manipulación de páginas HTML con JavaScript, JDOM se creó específicamente para usarse con Java™ y por lo tanto beneficiarse de las características de éste, incluyendo sobrecarga de métodos, colecciones, etc. Para los programadores de Java™, JDOM es una extensión más natural y correcta. Se asemeja al sistema RMI³⁹

³⁶ JDOM. <http://www.jdom.org/index.html>

³⁷ DOM (Document Object Model). <http://www.w3.org/DOM/>

³⁸ W3C. <http://www.w3c.es/Consortio/>

³⁹ RMI. http://es.wikipedia.org/wiki/Java_Remote_Method_Invocation

optimizado para Java™ (invocación remota de métodos), y se amolda mejor que CORBA⁴⁰ (arquitectura de intermediario solicitador de objetos comunes) que es más neutral respecto a los lenguajes.

El sistema usa JDOM para crear un árbol a partir del fichero XML asociado al documento. Recorriendo el árbol, el sistema es capaz de obtener el texto del documento, así como la información que nos interesa: título, autores, fecha de publicación y *abstract*, entre otros. Además, podemos eliminar los nodos del árbol que no consideremos interesantes para crear el resumen y que no se quiera mostrar como parte del texto, tales como tablas, imágenes o bibliografía.

4.2.2. Apache PDFBox

Apache PDFBox⁴¹ es una API de Java™ para trabajar con documentos PDF. Se publica bajo la licencia Apache v2.0⁴².

Esta librería permite crear documentos PDF, manipular ficheros PDF ya existentes e incluso extraer el contenido de un fichero PDF. Esta última función es la que nos interesa para el sistema. Para facilitar el trabajo se hace uso de PDF Text Parser.

⁴⁰ CORBA. <http://es.wikipedia.org/wiki/CORBA>

⁴¹ Apache PDFBox. <http://pdfbox.apache.org/index.html>

⁴² Licencia Apache v2.0. <http://www.apache.org/licenses/LICENSE-2.0>

PDF Text Parser

PDF Text Parser⁴³ se trata de una clase creada por Prasanna Seshadri⁴⁴, que convierte el contenido de un fichero PDF a texto plano usando la librería Apache PDFBox.

El sistema hace uso de esta clase Java™, para la extracción del texto que contiene el documento PDF cargado por el usuario, y poder trabajar con texto plano.

FontBox

FontBox⁴⁵ es una biblioteca de código abierto Java™ para analizar las distintas fuentes. Es necesario para que PDFBox pueda reconocer todas las fuentes de texto usadas en los ficheros PDF.

4.2.3. URL de la página web BioMed Central

En el caso de insertar una URL en el sistema, debe quedar claro que sólo funciona correctamente con una dirección web de BioMed Central que contenga un documento.

El sistema en este caso busca la existencia del fichero XML asociado al documento y comienza a trabajar con él. Se trataría de un paso intermedio para obtener el fichero XML.

⁴³ PDF Text Parser. <http://www.prasannatech.net/2009/01/convert-pdf-text-parser-java-api-pdfbox.html>

⁴⁴ Techtalks. A Technical Blog... <http://www.prasannatech.net/>

⁴⁵ FontBox. <http://sourceforge.net/projects/fontbox/>

4.2.4. RTFEditorKit

La clase RTFEditorKit de Swing, nos proporciona las herramientas necesarias para trabajar con documentos RTF. Se trata de unos archivos de texto con formato enriquecido creado por Microsoft.

RTFEditorKit se utiliza en el sistema para la extracción del texto en dichos documentos. Además está capacitada para ignorar imágenes gráficas incrustadas en el archivo RTF.

4.2.5. Jakarta POI

Jakarta POI⁴⁶ se trata de un proyecto consistente en APIs para manipular varios formatos de ficheros basados en el formato de Documento Compuesto OLE 2 de Microsoft (MS), utilizando Java™. En concreto, se pueden leer y escribir ficheros MS Excel (XLS) y MS Word (DOC).

En un principio se añadió dicha funcionalidad al sistema, pero visto que no se usará el formato MS Word en la aplicación, se eliminó. Los formatos más comunes para BioMed Central son PDF y XML.

4.3. Detector de idioma

Una vez que el sistema ha obtenido el texto del documento, necesitamos saber el idioma en el que está escrito dicho documento, para poder trabajar con él en la obtención de las frases que lo forman y los conceptos médicos asociados.

⁴⁶ Jakarta POI. <http://poi.apache.org/trans/es/index.html>

El sistema está preparado actualmente para trabajar con textos escritos en inglés y castellano, con la diferencia de que la detección de conceptos médicos con MetaMap sólo está disponible para documentos en inglés. A continuación vemos las propuestas con las que hemos trabajado y el inconveniente de cada una de ellas.

4.3.1. Google-API-translate-java

Google-api-translate-java⁴⁷ se trata de una API creada por Google para dar soporte a la traducción de texto desde Java™, usando la herramienta Google Translate⁴⁸.

En un primer momento, fue la solución adoptada en el sistema, pero el problema es que la API está creada para obtener el texto traducido, sin indicar el idioma obtenido automáticamente. La solución que se planteó consistía en buscar el idioma en el código fuente de la página web que se obtiene y fue descartada debido a que el código de dicha web fue modificado varias veces durante el desarrollo de la aplicación, y por lo tanto, había que modificar el código de nuestro sistema para adaptarlo a dicha página web.

4.3.2. JLangDetect

JLangDetect⁴⁹ es una implementación de Java™ de un detector de idioma, creado por la empresa Lingway⁵⁰. Proporciona un conjunto de herramientas para el reconocimiento de la formación lingüística, y una implementación simple de un detector.

⁴⁷ google-api-translate-java. <http://code.google.com/p/google-api-translate-java/>

⁴⁸ Google Translate. <http://translate.google.com/>

⁴⁹ JLangDetect. <http://code.google.com/p/jlangdetect/>

⁵⁰ Lingway. <http://www.lingway.com/>

Se implementó dicha herramienta en el sistema, pero una serie de pruebas mostraron algún error a la hora de detectar el idioma, sobre todo utilizando textos cortos, por lo que fue descartada.

4.3.3. Java Text Categorizing Library

JTCL⁵¹ es una implementación de la libTextCat⁵², que se trata de una librería desarrollada principalmente para la detección de idioma, tarea en la que necesitamos una precisión exacta. Se distribuye bajo licencia GPL⁵³.

El algoritmo de análisis de texto se basa en la técnica de clasificación descrita en Cavnar y Trenkle, 1994, que trata sobre la clasificación de textos basándose en n-gramas.

Tras las pruebas realizadas con los sistemas anteriores, y los resultados obtenidos con JTCL, se ha decidido usar JTCL debido a la rapidez y al porcentaje casi nulo en detecciones erróneas del idioma.

JTCLC tiene como opción limitar el número de caracteres para detectar el lenguaje de manera más rápida. Tras una serie de pruebas en la que se limitaba a 100, 200 y 500 caracteres, seleccionando tanto el principio como la parte central del documento, se observa que no se obtiene una mejora significativa de la velocidad, por lo que se ha optado por no limitar el número de caracteres.

⁵¹ JTCL (Java Text Categorizing Library). <http://textcat.sourceforge.net/>

⁵² libTextCat. <http://software.wise-guys.nl/libtextcat/>

⁵³ Licencia GPL. <http://www.gnu.org/copyleft/lesser.html>

4.4. Detector de frases

Una vez extraído el texto del documento y conocido el idioma en el que está escrito, el siguiente paso es obtener las frases que componen el texto, para que el usuario pueda ir seleccionando las que crea que deban formar parte del resumen.

4.4.1. MetaMap

El propio MetaMap, posee un sistema de división en frases, que podemos usar para obtener las que componen el texto. Pero usar este sistema conlleva un par de inconvenientes.

Por un lado, debemos pasarle a MetaMap el texto al completo, lo que hace que el sistema aumente considerablemente el tiempo necesario, en la actividad conjunta de detectar las frases y los conceptos médicos del texto.

Y por otro lado, en el reconocimiento de frases se cometían muchos fallos, resolviendo las ambigüedades de la manera más fácil. Es decir, optando en muchos casos por considerar el carácter punto (".") como separador de frases.

Por ejemplo, si le pasamos a MetaMap la siguiente frase: "For example let-7 family of miRNAs identified in C. elegans, Drosophila, Zebrafish or Human", se obtiene como salida lo mostrado en la figura 4.1.

Dos frases:

- For example let-7 family of miRNAs identified in C.
- elegans, Drosophila, Zebrafish or Human

Figura 4.1. Ejemplo de detector de frases con MetaMap

4.4.2. OpenNLP Tools

OpenNLP⁵⁴ se trata de una serie de proyectos de código abierto relacionados con el procesamiento del lenguaje natural. Su función principal es la de estimular y facilitar la colaboración entre investigadores y desarrolladores en este tipo de proyectos.

Para el sistema nos centramos en uno de estos proyectos, OpenNLP Tools, que consiste en una colección de herramientas entre las que se incluye un detector de frases.

En las pruebas realizadas nos encontramos con que si la herramienta no encuentra un punto, lo toma todo como una misma frase. Por ejemplo, cuando tenemos en un documento un título de apartado, al no tener punto el final de los títulos, lo une con la primera frase del siguiente párrafo, obteniendo por ejemplo: “Background A family of ~22 nucleotide noncoding RNAs termed microRNA...”, cuando en el documento original es:

Background

A family of ~22 nucleotide noncoding RNAs termed microRNA...

Figura 4.2. Ejemplo de detector de frases con OpenNLP Tools

Pero este problema, al contrario del que teníamos con MetaMap tiene una fácil solución. Cuando trabajamos con ficheros XML cada uno de los párrafos viene determinado por las etiquetas “<p> ... </p>”. Si se realiza un pre-procesado en el que dividimos el documento en párrafos y posteriormente a cada párrafo le pasamos la herramienta de OpenNLP, obteniendo las frases que contiene el párrafo, el problema queda solucionado.

⁵⁴ OpenNLP. <http://opennlp.sourceforge.net/>

4.5. Obtener conceptos UMLS®

Como explicamos en el capítulo 2, tenemos dos opciones para la obtención de los conceptos UMLS asociados a un documento, MMTx y MetaMap. En este apartado veremos el modelo propuesto y los inconvenientes de cada uno:

4.5.1. MMTx

Se trata de la versión adaptada a Java de MetaMap. Su principal inconveniente es que necesita un mayor tiempo para la obtención de los conceptos, y la diferencia de los resultados obtenidos con respecto a MetaMap.

4.5.2. MetaMap Java API

Es la propuesta usada en el sistema. El proceso de trabajo será:

1. Arrancar el servidor de MetaMap.
2. Procesar cada una de las frases que componen el documento original, de forma que la API devuelve la relación de conceptos UMLS encontrados en cada una de las frases.
3. Por último, se almacenan los conceptos de cada frase en nuestra estructura, para posteriormente poder rescatarlos de una manera rápida.

Por ejemplo, en el caso de seleccionar una frase para el resumen, necesitamos los conceptos asociados a dicha frase para actualizar la lista de conceptos con las frecuencias asociadas. O al cargar un documento con la estructura ya creada, no necesitamos volver a calcular los conceptos con el servidor MetaMap, sino que los rescatamos de la propia estructura.

4.5.3. Servidor MetaMap

Es el propio MetaMap en sí, y sus principales inconvenientes son: la cantidad de espacio requerido en disco (del orden de 10 GB), la cantidad de memoria requerida para trabajar (recomienda 2 GB) y la imposibilidad de usar un sistema operativo distinto a Linux⁵⁵ o Solaris⁵⁶.

Para poder usar MetaMap en nuestro sistema, se ha tenido que instalar el sistema operativo Linux en la distribución Ubuntu 9.10⁵⁷ 32 bits, puesto que el núcleo de MetaMap sólo está compilado para este caso, no funcionando en versiones de 64 bits. En el apéndice I se explica detalladamente el proceso de instalación.

Una vez que MetaMap está totalmente instalado en el sistema, tan sólo tenemos que tener arrancado el servidor para que pueda aceptar las llamadas desde la API de Java™.

El anexo I, contiene una guía con todos los pasos necesarios para una correcta instalación del servidor MetaMap.

4.6. Base de datos

Para el almacenamiento de los datos requeridos por el sistema, vamos a configurar una base de datos en MySQL.

⁵⁵ Linux. <http://es.wikipedia.org/wiki/GNU/Linux>

⁵⁶ Solaris. [http://es.wikipedia.org/wiki/Solaris_\(sistema_operativo\)](http://es.wikipedia.org/wiki/Solaris_(sistema_operativo))

⁵⁷ Linux Ubuntu. <http://www.ubuntu.com/>

4.6.1. MySQL

MySQL se trata de un sistema de gestión de base de datos relacional, multihilo y multiusuario. Se ha decidido usar este sistema porque es libre y multiplataforma y además porque poseo un servidor propio con MySQL instalado.

4.6.2. Servidor Synology DS-207

Synology⁵⁸ se trata de una compañía especializada en la producción de dispositivos de almacenamiento conectados a la red (NAS⁵⁹).

En mi caso dispongo de un servidor Synology modelo DS-207. Contiene en su interior dos discos duros de 1 TB cada uno montados en RAID1⁶⁰. Este servidor además de proporcionar almacenamiento centralizado, posee otras características como servidor FTP, servidor web con PHP y MySQL, servidor de descarga, servidor multimedia o servidor UPnP.



Figura 4.3. Servidor Synology DS207

⁵⁸ Synology. <http://www.synology.com/esp/index.php>

⁵⁹ NAS (Network Attached Storage). http://es.wikipedia.org/wiki/Network-attached_storage

⁶⁰ Sistema RAID. <http://es.wikipedia.org/wiki/RAID>

Viendo la posibilidad de usar el servidor MySQL, se configuró y se creó la base de datos necesaria para el sistema. Además la especial motivación de usar este servidor de base de datos era por dotar al sistema de mayor realismo para cuando se instale en su destino definitivo.

Para la configuración y mantenimiento de la base de datos, se puede usar cualquier cliente de MySQL. En este caso se ha usado Sequel Pro⁶¹ y PHPMyAdmin⁶². Ambos cumplen perfectamente su cometido, la única diferencia es que el primero es una aplicación de escritorio y el segundo una aplicación web.

⁶¹ Sequel Pro. <http://www.sequelpro.com/>

⁶² PHPMyAdmin. http://www.phpmyadmin.net/home_page/

5. Modelo de requisitos

En el capítulo anterior número 4, en este número 5 y en el siguiente número 6 se recogen los entregables del sistema AsGeRe siguiendo una metodología de desarrollo para una aplicación, desde el punto de vista ingenieril.

El propósito de este capítulo 5 es identificar y establecer los requisitos de la aplicación que vamos a crear.

5.1. Requisitos de información

Nombre	Información sobre usuarios
Identificador	RI-001
Autor	José María Bermúdez Peinado
Descripción	El sistema deberá almacenar la información correspondiente a los usuarios

Datos específicos	Identificador Nombre Contraseña
Importancia	Vital
Urgencia	Inmediata
Estado	Construido

Nombre	Información sobre documentos
Identificador	RI-002
Autor	José María Bermúdez Peinado
Descripción	El sistema deberá almacenar la información correspondiente a los documentos
Datos específicos	Identificador Título Usuario creador Fecha de inserción en el sistema Texto del documento Autores Fecha de publicación Idioma Lista de frases Lista de conceptos
Importancia	Vital
Urgencia	Inmediata
Estado	Construido

Nombre	Información sobre resúmenes
Identificador	RI-003
Autor	José María Bermúdez Peinado
Descripción	El sistema deberá almacenar la información correspondiente a los resúmenes
Datos específicos	Identificador Título Documento Usuario creador Fecha de creación Texto del resumen
Importancia	Vital
Urgencia	Inmediata
Estado	Construido

5.2. Requisitos funcionales

5.2.1. Definición de actores

El sistema tiene dos actores claramente identificados, el Usuario y el Administrador.

Nombre	Administrador
Identificador	ACT-001
Autor	José María Bermúdez Peinado
Descripción	Este actor representa al administrador del sistema

Nombre	Usuario
Identificador	ACT-002
Autor	José María Bermúdez Peinado
Descripción	Este actor representa al usuario de la aplicación

5.2.2. Diagramas de casos de uso




Figura 5.1. Diagrama de casos de uso del sistema

5.2.3. Casos de uso del sistema

Nombre	Identificación de usuario
Identificador	CU-001
Autor	José María Bermúdez Peinado
Descripción	Permite a los usuarios identificarse en el sistema
Actores	Usuario, Administrador
Precondiciones	El actor aún no puede estar identificado
Flujo normal	1. El actor introduce su nombre de usuario 2. El actor introduce su password 3. El actor pulsa el botón "Login" 4. El sistema comprueba que los datos son correctos 5. El sistema muestra la interfaz principal
Flujo alternativo	4. El sistema comprueba que los datos no son correctos o falta alguno, se avisa al actor permitiéndole que los modifique
Postcondiciones	El actor queda identificado en el sistema

Nombre	Cargar documento desde la base de datos
Identificador	CU-002
Autor	José María Bermúdez Peinado
Descripción	Permite al usuario mostrar los documentos indexados en la base de datos y seleccionar uno para poder trabajar con él
Actores	Usuario, Administrador
Precondiciones	El actor debe estar identificado (CU-001)
Flujo normal	1. El actor pulsa el botón “Cargar BD” 2. El sistema accede a la base de datos, obtiene la información para mostrar sobre cada uno de los documentos indexados y los muestra en la interfaz 3. El actor selecciona un documento de la lista 4. El sistema obtiene la estructura del documento seleccionado y lo muestra en la interfaz
Flujo alternativo	-
Postcondiciones	El actor puede comenzar a trabajar con el documento

Nombre	Abrir documento desde un fichero
Identificador	CU-003
Autor	José María Bermúdez Peinado
Descripción	Permite al usuario trabajar con un documento cargado desde un fichero
Actores	Usuario, Administrador
Precondiciones	El actor debe estar identificado (CU-001)
Flujo normal	1. El actor pulsa el botón de “Abrir Fichero” 2. El sistema muestra un explorador de los ficheros que existen en el equipo 3. El actor selecciona el fichero deseado 4. El sistema extrae el texto del documento 5. El sistema obtiene el título, autores, fecha de publicación y <i>abstract</i> 6. El sistema obtiene el idioma. Divide el texto en frases. Obtiene los conceptos UMLS. Inserta un nuevo documento en la base de datos y el <i>abstract</i> como un nuevo resumen 7. El sistema muestra el documento en la interfaz
Flujo alternativo	3. El actor pulsa el botón cancelar, el sistema vuelve a la interfaz principal 5. Si el fichero no es XML, solicita al usuario que introduzca manualmente la información necesaria (Título, autores, fecha de publicación y <i>abstract</i>) 6. El sistema busca el título en la base de datos y si ya existe indexado, carga el documento desde la base de datos
Postcondiciones	El actor puede comenzar a trabajar con el documento. Nuevo documento disponible en la base de datos y resumen asociado, si el documento no estaba indexado

Nombre	Abrir documento desde la URL de una página web
Identificador	CU-004
Autor	José María Bermúdez Peinado
Descripción	Permite al usuario trabajar con un documento cargado desde una dirección web de BioMed Central
Actores	Usuario, Administrador
Precondiciones	El actor debe estar identificado (CU-001)
Flujo normal	1. El actor pulsa el botón de “Abrir URL” 2. El actor introduce la URL 3. El actor pulsa el botón “Procesar” 4. El sistema descarga el fichero XML desde la página web 5. El sistema obtiene el título, autores, fecha de publicación y <i>abstract</i> 6. El sistema obtiene el idioma. Divide el texto en frases. Obtiene los conceptos UMLS. Inserta un nuevo documento en la base de datos y el <i>abstract</i> como un nuevo resumen 7. El sistema muestra el documento en la interfaz
Flujo alternativo	4. La página web no pertenece a BioMed Central o no contiene el fichero XML que necesitamos. El sistema no hace nada 6. El sistema busca el título en la base de datos y si ya existe indexado, carga el documento desde la base de datos
Postcondiciones	El actor puede comenzar a trabajar con el documento Nuevo documento disponible en la base de datos y resumen asociado, si el documento no estaba indexado

Nombre	Abrir documento desde un texto editado
Identificador	CU-005
Autor	José María Bermúdez Peinado
Descripción	Permite al usuario trabajar con un documento editado
Actores	Usuario, Administrador
Precondiciones	El actor debe estar identificado (CU-001)
Flujo normal	1. El actor pulsa el botón de “Pegar texto” 2. El sistema modifica el cuadro de texto como editable 3. El actor pega y/o escribe el texto 4. El actor pulsa el botón “Procesar” 5. El sistema solicita al usuario que introduzca manualmente la información necesaria (Titulo, autores, fecha de publicación y <i>abstract</i>) 6. El sistema extrae el texto. Obtiene el idioma. Divide el texto en frases. Obtiene los conceptos UMLS. Inserta un nuevo documento en la base de datos y el <i>abstract</i> como un nuevo resumen 7. El sistema muestra el documento en la interfaz
Flujo alternativo	-
Postcondiciones	El actor puede comenzar a trabajar con el documento Nuevo documento disponible en la base de datos y resumen asociado, si el documento no estaba indexado

Nombre	Seleccionar una frase
Identificador	CU-006
Autor	José María Bermúdez Peinado
Descripción	Se añade una nueva frase del texto del documento al resumen del usuario
Actores	Usuario, Administrador
Precondiciones	- El actor debe estar identificado (CU-001) - Debe haber un documento cargado en el sistema
Flujo normal	1. El actor pulsa sobre un carácter en la pantalla del texto del documento 2. El sistema sombrea la frase completa que contiene el carácter seleccionado y añade la frase en el cuadro resumen, manteniendo el orden que presentan en el documento original
Flujo alternativo	2. Si selecciona un carácter de una frase ya seleccionada anteriormente, se elimina su sombreado y del cuadro del resumen
Postcondiciones	El actor puede continuar trabajando con el documento

Nombre	Guardar resumen
Identificador	CU-007
Autor	José María Bermúdez Peinado
Descripción	Inserta un nuevo resumen en la base de datos del sistema
Actores	Usuario, Administrador
Precondiciones	- El actor debe estar identificado (CU-001) - Debe haber un documento cargado en el sistema - El resumen no puede estar vacío
Flujo normal	1. El actor pulsa el botón de “Guardar Resumen” 2. El sistema inserta un nuevo resumen en la base de datos, asociado al documento con el que se está trabajando y al usuario identificado.
Flujo alternativo	-
Postcondiciones	El actor puede continuar trabajando con el documento

Los casos de usos propios del administrador, se han resuelto en el sistema mediante herramientas externas. Son las funciones sobre la base de datos MySQL, por lo tanto, para ambos casos de usos, se puede utilizar cualquier cliente MySQL.

En nuestro caso se han utilizado tanto PHPMyAdmin (aplicación web) como Sequel Pro (aplicación de escritorio). Hay un detallado manual de empleo al final del capítulo 8, manual del usuario.

5.3. Requisitos no funcionales y/o técnicos

Nombre	El sistema debe funcionar en cualquier sistema operativo
Identificador	RNF-001
Autor	José María Bermúdez Peinado
Descripción	Se considera importante que la aplicación funcione bajo cualquier tipo de sistema operativo
Importancia	Vital
Comentarios	Se desarrollará en Java™ para conseguir una mayor portabilidad.

Nombre	El sistema debe desarrollarse con software gratuito
Identificador	RNF-002
Autor	José María Bermúdez Peinado
Descripción	Se considera importante que la aplicación sea desarrollada con software gratuito
Importancia	Vital
Comentarios	Se desarrollará en la plataforma NetBeans y para la base de datos se usará MySQL.

5.4. Prototipo de la aplicación

Con respecto a los requisitos obtenidos en una primera entrevista y viendo las necesidades del sistema, se plantearon una serie de prototipos para la interfaz. La seleccionada como más práctica con respecto a la distribución de las distintas zonas es la que se presenta en la figura 5.2, muy parecida a la interfaz final de la aplicación.



The image shows a wireframe of a web application titled "AsGeRe". The interface is divided into several sections:

- Documentos:** A section on the left containing an "Abrir fichero:" button and a text input field labeled "Ruta del fichero". Below this is a large text area labeled "Texto que contiene el documento".
- Resumen:** A section on the right containing a "Guardar Resumen" button and a text area labeled "Resumen generado por el usuario".
- Estadísticas:** A section below the "Resumen" section containing a single text input field.
- Lista de conceptos del documento:** A table below the "Estadísticas" section with two columns: "Fre." and "Concepto".
- Lista de conceptos del resumen:** A table to the right of the "Lista de conceptos del documento" section, also with two columns: "Fre." and "Concepto".

Figura 5.2. Prototipo de la aplicación

5.5. Estimación de costes

Para la estimación de costes del sistema se ha utilizado la técnica de estimación por analogía. Esta técnica es aplicable cuando se han completado otros proyectos en el mismo dominio de aplicación y con cierto parecido al sistema que estamos creando. Se estima el costo de un nuevo proyecto por analogía con estos proyectos completados. Además, debemos tener en cuenta los costes de personal desarrollador, hardware y licencias de software.

Para el desarrollo de la planificación por casos de uso realizada anteriormente y en comparación con otros sistemas desarrollados con anterioridad, sabemos que aproximadamente se tardará 6 meses en realizar el proyecto. Suponiendo un sueldo de 1.593,60 €/mes⁶³ por desarrollador, el coste de personal será:

$$1.593,60 \text{ €/mes} \times 1 \text{ desarrollador} \times 6 \text{ meses} = 9.561,60 \text{ €}$$

Para el hardware, se supone que se puede instalar en cualquier ordenador ya disponible, por lo que no acarrea coste extra.

Y para las licencias de software, hay que tener en cuenta que se usará sistema operativos Linux Ubuntu, que tampoco acarrea coste extra.

Por lo tanto el **coste total del sistema** será de **9.561,60 €**.

⁶³ Datos obtenidos de las tablas salariales del convenio colectivo de 2010 de Siemens SA publicadas en el BOE N° 260 del 28 de Octubre de 2009.

<http://www.boe.es/boe/dias/2009/10/28/pdfs/BOE-A-2009-17107.pdf>

El sueldo corresponde a un analista programador.

6. Modelo de diseño

Una vez establecidos los requisitos del sistema, pasamos a la fase de análisis. En este capítulo se presenta el diagrama de clases del sistema desarrollando cada una de las clases. Se incluye además el comportamiento dinámico del sistema mediante los diagramas de secuencia.

6.1. Diagrama de clases





Figura 6.1. Diagrama de clases del sistema



6.2. Clases

6.2.1. Paquete data

Paquete que contiene la implementación de todo lo referente con la capa de acceso a datos.

BaseDatos

Contiene los procedimientos necesarios para la conexión con la base de datos MySQL. Conectarse y desconectarse, comprobar un usuario, insertar un nuevo documento y un nuevo resumen, cargar un documento y obtener un listado de los documentos indexados.

6.2.2. Paquete extractText

Contiene lo necesario para la extracción del texto y demás información necesaria desde los distintos tipos de fichero que maneja el sistema.

XML2Text

Para extraer el texto y la información desde ficheros XML. Hace uso de la librería JDOM. Además del texto del documento, es capaz de obtener el título, autores, fecha de publicación y *abstract*. También elimina del texto la información menos relevante para la creación de un resumen, como son las imágenes, tablas o referencias.

PDF2Text

Se encarga de obtener el texto que contiene un fichero PDF dada una dirección de un fichero. Para ello hace uso de la clase PDFTextParser.

PDFTextParser

Clase creada por Prasanna Seshadri, que convierte el contenido de un fichero PDF a texto plano.

TXT2Text

Obtiene el texto de un fichero de tipo TXT dada la dirección del fichero.

RTF2Text

Obtiene el contenido de un fichero de tipo RTF.

6.2.3. Paquete log

Logger

Mantiene un fichero *log* del sistema. Cuando la aplicación genera un nuevo evento, manda un mensaje al *logger*, éste le añade la fecha y hora en la que se produce y además de mostrarlo por consola, lo guarda en un documento de texto.

6.2.4. Paquete metamap

MetaMap

Se encarga de obtener los conceptos biomédicos de un texto. Para los textos en castellano, realiza los procedimientos de *Stemmer* y *Stopper*.

Stopper

Se trata de un algoritmo que dado un texto elimina las palabras vacías.

Stemm_es

Algoritmo de Porter en castellano para la reducción a la raíz de las palabras que contiene un texto.

6.2.5. Paquete modelo

Paquete que contiene las clases donde se almacenará la información necesaria para el funcionamiento de la aplicación.

Documento

Contiene la información requerida por el sistema para el documento con el que trabaja. Por ejemplo: Texto, título, idioma, lista de frases que lo componen o la lista de conceptos. Además contiene todos los procedimientos necesarios para modificar y obtener dicha información.

Frase

Contiene la información necesaria de una frase del documento. Por ejemplo el texto, los conceptos que pertenecen a la frase o una variable que indica si pertenece o no al resumen.

Resumen

Contiene las frases del documento que han sido seleccionadas por el usuario para pertenecer al resumen.

Concepto

Contiene información de cada uno de los conceptos obtenidos por UMLS para un texto.

6.2.6. Paquete vista

AsGeRe

Implementa el interfaz principal de la aplicación, así como todo lo necesario para controlarla. Abrir ficheros, cargar documentos desde la base de datos, insertar nuevos documentos y resúmenes, control de las estadísticas y listas de conceptos y mostrar las ventanas para interactuar con el usuario.

6.2.7. Paquete tests

Contiene aplicaciones y pruebas necesarias durante la implementación. Inicialización de la base de datos, prueba para obtener el texto de un fichero, prueba de detección de idioma, frases y conceptos de un texto y las pruebas de conexión con la base de datos.

6.3. Capa de acceso a datos

La base de datos MySQL está formada por una serie de tablas representadas en el diagrama Entidad-Relación de la figura 6.3.

6.3.1. Tabla de usuarios

Contendrá la información requerida de los usuarios del sistema. La estructura de la tabla será la siguiente:

- id, identificador del usuario, en la base de datos (clave primaria).
- nombre, nombre del usuario
- pass, clave para acceder al sistema




Figura 6.3. Diagrama Entidad-Relación del sistema

6.3.2. Tabla de documentos

Guardará toda la información referente a los documentos indexados del sistema. La estructura será3

- id, identificador del documento (clave primaria), consiste en el título truncado a 20 caracteres, precedido de un número único.
- titulo, título del documento.
- usuario, identificador del usuario que ha generado el documento (clave foránea).
- fecha, fecha de creación del documento.
- texto, texto del documento
- autores, autores del documento
- fechapubli, es la fecha de publicación del documento
- idioma, el idioma en el que está escrito el documento
- frases, una lista con las frases que componen el documento
- conceptos, un listado de los conceptos que contiene el documento

6.3.3. Tabla de resúmenes

Guardará toda la información referente a los resúmenes generados por los usuarios del sistema y el *abstract* de cada documento. La estructura será:

- id, identificador del resumen (clave primaria), consiste en el identificador del documento añadiéndole al final un número único para los resúmenes de un mismo documento (0 para el *abstract*).
- documento, identificador del documento al que pertenece el resumen (clave foránea).
- usuario, identificador del usuario que ha generado el documento (clave foránea).
- fecha, fecha de creación del documento.
- texto, texto del resumen.

7. Despliegue del sistema

7.1. Diagrama de despliegue




Figura 7.1. Diagrama de despliegue del sistema

7.2. Arquitectura del sistema

En base al diagrama de despliegue, podemos ver que la aplicación hace uso de una serie de servidores externos.

Por un lado la aplicación requiere un **servidor de base de datos MySQL**, para almacenar toda la información necesaria por el sistema.

Por otro lado, necesitamos un **servidor MetaMap**, con el que descubrir los conceptos biomédicos asociados a un texto.

Por último, el sistema se trata de una aplicación de escritorio escrita en Java, que hace uso de la librería Swing para el motor gráfico.

8. Manual del usuario

En este capítulo, presentaremos el manual para conocer todo lo necesario para utilizar la aplicación. Realizaremos una introducción de las distintas partes de la interfaz de usuario, veremos las posibilidades de abrir un documento o cargarlo desde la base de datos, la forma de generar un resumen, así como aprovechar las ayudas que la aplicación ofrece para generar un resumen.

8.1. Identificación de usuario

Al abrir la aplicación, lo primero que nos encontramos es una ventana de identificación de usuario, donde se introduce el nombre de usuario y contraseña y pulsamos sobre el botón “Login”.



Figura 8.1. Ventana de identificación de usuario

8.2. Interfaz




Figura 8.2. Zonas de la interfaz

La interfaz principal de la aplicación, la podemos dividir en tres zonas, la zona del documento, del resumen y de las ayudas. Además en la parte superior izquierda tenemos un mensaje con el nombre del usuario conectado y un botón para dejar de estar identificado en el sistema.

Veamos ahora cada una de las partes anteriormente mencionadas:

- la zona de la izquierda (cuadro rojo), donde tenemos todo lo referente al documento con el que estamos trabajando. De arriba hacia abajo podemos ver las distintas posibilidades para abrir un documento, seguido del título del documento que tenemos abierto, y por último el texto del documento.

- la zona superior derecha (cuadro azul), que contiene el resumen que el usuario va generando, además del botón para guardar dicho resumen en la base de datos.

- la zona inferior derecha (cuadro verde), se trata de la zona de asistencia, y contiene la ayuda que ofrece la aplicación sobre el documento y el resumen para ayudar a que el autor genere su resumen. Podemos ver el cuadro de estadísticas, donde se muestra el número de palabras y frases que componen tanto el documento original como el resumen que se va generando, así como el porcentaje de palabras y frases que el resumen contiene del texto completo, y se especifica el idioma del documento. Bajo las estadísticas, tenemos las listas de conceptos médicos que contienen el texto y el resumen, ordenadas de manera descendente según la distribución de frecuencia. Por último, existe una barra inferior, donde la aplicación muestra mensajes de información de lo que va aconteciendo.

8.3. Cargar/Abrir documento



Figura 8.3. Cargar/Abrir documento

En la parte superior de la zona del documento, tenemos las distintas formas de cargar o abrir un documento. Como hemos mencionado anteriormente, podemos cargar un documento desde la base de datos, un fichero, una página web o bien pegando directamente el texto. Veamos cada uno de ellos.

8.3.1. Cargar desde la base de datos




Figura 8.4. Cargar documento desde la base de datos

En la opción “Base de Datos” podemos presionar sobre el botón “Cargar BD”, lo que nos facilitará un listado de todos los documentos que ya existen indexados en la base de datos del sistema.

Para cada documento, se muestra la información de la manera que muestra la figura 8.5.

<u>Título del documento</u>
<i>Autores</i>
<i>Fecha de publicación</i>

Figura 8.5. Información de los documentos indexados

Una vez encontrado el documento con el que queremos trabajar, sólo hay que pulsar sobre él y se cargará en la interfaz. Ya podemos comenzar a trabajar con el documento.

8.3.2. Abrir archivo




Figura 8.6. Abrir fichero

En el caso que seleccionemos la opción de abrir el documento desde un archivo, se nos muestra un explorador de ficheros donde seleccionamos el archivo deseado. Cabe recordar que el sistema soporta archivos XML, siendo capaz además de abrir otro tipo de ficheros como PDF, TXT, RTF.

Una vez seleccionado el fichero deseado, el sistema comienza a trabajar sobre él. Extrae el texto y busca si ya existe en la base de datos. Si existe, carga la estructura para comenzar a trabajar, en cambio, si el documento no está indexado en la base de datos genera toda la estructura necesaria, lo indexa automáticamente en la base de datos y prepara la interfaz para que el usuario comience a trabajar.




Figura 8.7. Ventana explorador de Abrir fichero

8.3.3. Abrir página web

La aplicación está diseñada principalmente para trabajar con documentos de BioMed Central. Si el documento con el que queremos trabajar se encuentra indexado en dicho repositorio, podemos insertar en nuestro sistema directamente la página web que lo contiene.




Figura 8.8. Abrir página web

Una vez pegada la URL, se pulsa el botón “Procesar” y comienza a trabajar. Se inicia la búsqueda del fichero XML asociado a dicho documento en la página web, en el caso de que no exista el sistema no muestra nada. Si existe en formato XML, se descarga el fichero, y comienza a trabajar con él. Una vez obtenido el texto, busca su existencia en la base de datos. En caso afirmativo carga la estructura, en caso negativo, genera la estructura e indexa el documento automáticamente en la base de datos. Llegados a este punto, podemos comenzar a trabajar.

8.3.4. Pegar Texto




Figura 8.9. Pegar texto

Por último, otra opción para comenzar a trabajar, se trata de pegar el texto en nuestro sistema. Pulsando el botón “Pegar”, podemos editar el cuadro del texto, podemos pegar y escribir el texto que se desee. Una vez terminado de editar el texto, pulsamos el botón “Procesar” y el sistema comenzará a trabajar con el texto.

8.4. XML

Nuestro sistema está preparado para trabajar con ficheros de tipo XML generados por BioMed Central. Se trata de unos ficheros con información etiquetada. Los generados por BioMed Central, se crean a partir del PDF original siguiendo una hoja de estilos, por lo que todos poseen una estructura determinada. Esta estructura común va a servir al sistema para ser capaz de extraer de manera automática la información que nos interesa, como el título del documento, los autores, la fecha de publicación y el *abstract*, insertando todos los datos en la base de datos, incluyendo el *abstract* que será el primer resumen asociado al documento.

En el caso de que el fichero no sea un documento XML, nuestro sistema no es capaz de extraer la información necesaria para indexarlo en la base de datos. En dicho caso, el sistema muestra una ventana emergente solicitando al usuario dicha información.


A screenshot of a web application window. At the top, there is a message in Spanish: "Para mejorar el funcionamiento de la aplicación, sería de gran ayuda rellenar estos datos sobre el texto. (Puedes copiar y pegar desde el documento original). ¡Gracias!". Below this message are three input fields: "Titulo:" followed by a single-line text box, "Autor/es:" followed by a single-line text box, and "Abstract:" followed by a larger multi-line text box. At the bottom, there is a section for "Fecha de publicación:" with three small input boxes labeled "día", "mes", and "año". To the right of these boxes is a button labeled "Guardar".

Figura 8.10. Ventana de solicitud de información para documentos no XML

Es importante la buena utilización de esta ventana, puesto que estos datos son los necesarios para el perfecto funcionamiento del sistema, y sobre todo para el ahorro de tiempo de los usuarios posteriores al cargar un documento ya indexado en el sistema.

Una vez introducido los datos, se pulsa el botón “Guardar” y el sistema busca el título introducido en la base de datos, por si el documento ya estuviera indexado. En caso contrario, comienza a trabajar con el documento para generar la estructura necesaria e insertarlo en la base de datos del sistema.

8.5. PDF

En el caso de trabajar con archivos PDF descargados desde BioMed Central, el sistema está capacitado para obtener el fichero XML (si existe) desde la propia página web de BioMed Central, con el correspondiente beneficio de trabajar con un documento XML.

8.6. Documento cargado




Figura 8.11. Documento cargado

Éste es el aspecto de la aplicación al finalizar el proceso de cargar. Como novedades vemos el título y el texto del documento cargado, así como la lista de conceptos y estadísticas pertenecientes al texto. En cambio, el campo del texto, la lista de conceptos y las estadísticas pertenecientes al resumen, se encuentran inicializados. Ya está todo preparado para generar el resumen.

8.7. Generar resumen

Para generar un resumen, el usuario debe hacer click en las frases del texto que crea conveniente, y se irán subrayando en distintos colores para poder distinguirlas. Se agregarán al campo texto del resumen de manera automática, así como se actualizarán las estadísticas y la lista de conceptos pertenecientes al resumen.




Figura 8.12. Resumen generado

Si en algún momento el usuario selecciona una frase no deseada por error, tan sólo tendrá que volver a hacer click sobre ella para eliminar dicha selección y así eliminarla del resumen.

Una vez terminado el resumen, para guardarlo en la base de datos, hay que pulsar sobre el botón “Guardar en BD” en la zona de resumen. Automáticamente se insertará en la base de datos.


8.8. Ayudas del sistema

El sistema nos ofrece una serie de ayudas para asistir en la creación del resumen por parte del usuario. Tenemos las estadísticas, las listas de conceptos y la barra inferior de estados.

8.8.1. Estadísticas

Una de las ayudas que nos aporta el sistema consiste en las estadísticas del texto del documento original y del resumen.

Por un lado, nos muestra el idioma detectado de manera automática del documento original.



	Texto	Resumen	%	Idioma detectado:
Palabras	3234	111	3,432	Inglés
Frases	156	4	2,564	

Figura 8.13. Estadísticas

Además muestra un cuadro donde podemos ver el número de palabras y frases que componen el texto y el resumen, y el porcentaje que forma el resumen que vamos generando, con respecto del documento original.

Cabe destacar, que las estadísticas del resumen se van actualizando automáticamente en tiempo real conforme se van seleccionando frases del texto.

8.8.2. Listas de conceptos

Otra ayuda que nos ofrece el sistema, se trata de la lista de conceptos biomédicos obtenidos mediante UMLS, que contienen tanto el documento original como el resumen que se va creando.

Los conceptos llevan asociados un número que indica la frecuencia de aparición de dicho concepto en el texto, o en el resumen creado. Las listas están ordenadas por dicha frecuencia. Estos datos ayudan al usuario a comparar las distribuciones de texto y resumen generado.




Figura 8.14. Listas de conceptos

Al igual que la tabla de estadísticas, la lista de conceptos del resumen también va actualizándose automáticamente en tiempo real a medida que se va seleccionando frases del documento.

8.8.3. Barra de estado

Como ayuda adicional del sistema, en la parte inferior del mismo, se encuentra una barra de estado que va indicando todas las novedades acontecidas en el sistema.

Como ejemplo se muestran algunos de los mensajes:



Figura 8.15. Ejemplos de mensajes en la barra de estado

8.9. Administrador del sistema

El usuario administrador es el encargado de gestionar la base de datos para el ingreso de nuevos usuario o la obtención de los resúmenes. Para ambas tareas se puede hacer uso de cualquier cliente MySQL y conectarse a la base de datos *asgeredb*. Sequel Pro o PHPMyAdmin son algunos ejemplos de aplicaciones clientes MySQL.

8.9.1. Sequel Pro

Un ejemplo de herramienta para trabajar con una base de datos MySQL es Sequel Pro, se trata de una aplicación de escritorio desarrollada para Mac, pero muy similar a cualquier otro cliente MySQL. Veamos un ejemplo de uso.

Al abrir el programa, se solicitan los parámetros necesarios para conectarse a la base de datos, como muestra la figura 8.16.



Figura 8.16. Sequel Pro, conexión a la base de datos

Para visualizar el contenido de una de las tablas, sólo hay que seleccionarla en la barra lateral. Por ejemplo, la tabla DOCUMENTOS, como muestra la figura 8.17.




Figura 8.17. Sequel Pro, visualizar contenido de la tabla DOCUMENTOS

Para insertar un nuevo usuario, seleccionamos la tabla USUARIOS, pulsamos el botón + de la barra inferior y se introducen los datos necesarios, como muestra la figura 8.18.




Figura 8.18. Sequel Pro, crear un nuevo usuario

9. Conclusiones y trabajos futuros

9.1. Conclusiones

Como conclusiones podemos comenzar confirmando que a lo largo de esta memoria se ha presentado una aplicación que soluciona la escasa asistencia que existe (existía) en el campo de la creación de un *Gold Standard*. Se ha cumplido el objetivo de ayudar al usuario a la hora de crear resúmenes que posteriormente se utilizarán en proyectos de evaluación y generación automática de resúmenes.

Con respecto a los objetivos planteados al inicio de este trabajo, hemos visto como se han ido cumpliendo satisfactoriamente.

Para el desarrollo se han utilizado lenguajes y plataformas que hacen de la aplicación una **herramienta portable** para cualquier sistema. Con gasto nulo en licencias de software y soporte.

Se ha creado una **base de datos** acorde a las necesidades del sistema, donde almacenar toda la información necesaria. Se ha instalado en un servidor

externo para dar mayor realismo en la futura instalación final del sistema. Además, la herramienta está capacitada para buscar automáticamente documentos ya indexados en la base de datos al cargar un documento desde un fichero o desde una página web, para conseguir una mayor rapidez de trabajo, así como insertar documentos que aún no han sido procesados e indexados en el sistema, y sus *abstracts* asociados.

Dado un documento proveniente tanto de una **página web, como de un fichero** ya sea **de tipo TXT, RTF, PTF o XML**, la aplicación cumple satisfactoriamente su cometido, siendo capaz de extraer el texto que contiene.

Con el texto del documento, la aplicación está capacitada para extraer la máxima información posible. Si trabajamos con documentos XML, es capaz de obtener de manera autónoma toda la información relevante del documento: título, autores, fecha de publicación y *abstract*. Y es capaz de eliminar la información que no interesa presentar al usuario, por ejemplo el *abstract*, para no influenciarlo en la generación del resumen, u otros datos innecesarios como son las imágenes, tablas, referencias o agradecimientos.

Además la aplicación es capaz de **averiguar el idioma** en el que está escrito el documento y **obtener las frases** que lo componen.

Por último, la aplicación asiste al usuario con una serie de **estadísticas** propias del texto del documento y del resumen que se va generando, actualizando dicha información en tiempo real. Además de las estadísticas, tenemos dos listas que contiene los **conceptos médicos** detectados en el documento y en el resumen.

Destaca la capacidad de la herramienta para **obtener conocimiento** a partir del texto plano extraído del documento, siendo capaz de detectar los conceptos médicos que contiene un texto.

9.2. Trabajos futuros

Como posibles ampliaciones podemos hablar, por un lado, **a nivel de arquitectura**, que consistiría en conseguir que la herramienta se convierta en una aplicación web y poder instalarla en un servidor, haciendo de la herramienta un sistema centralizado utilizable por todo usuario desde Internet, sin depender de máquinas específicas con servidor MetaMap y de base de datos.

Además, **a nivel de conceptos**, se plantea como posible ampliación el conseguir la detección de conceptos biomédicos para textos escritos en castellano.

Por último, una ampliación que mejorara la extracción del texto desde los fichero PDFs, consiguiendo eliminar las cabeceras y pie de páginas que crean ruido y dificultan la detección de las frases por parte del sistema.

Anexo I: Instalación de MetaMap

Para el proceso de instalación, se han seguido los pasos detallados en la página web: <http://metamap.nlm.nih.gov/>

Lo primero que hay que tener en cuenta, es que necesitamos de un sistema operativo Linux, en nuestro caso usamos la distribución Ubuntu 9.10. Son necesarios además alrededor de 10 GB de capacidad en el disco y un mínimo de 1 GB de memoria RAM, aunque se recomiendan 2 GB.

El siguiente paso es obtener una cuenta UMLSKS, se realiza desde la página web: <https://login.nlm.nih.gov/cas/login>. Es importante en este sentido, aceptar el acuerdo de UMLSKS, que entre otros requisitos, exige presentar un breve informe al menos una vez al año sobre el uso de UMLS®. Además requiere el conocimiento de que UMLS® contiene material con derechos de autor y que estos sean respetados. Tras formalizar la solicitud, se ha de esperar en torno a 48 horas para la aceptación de la misma, y lograr así el acceso a zonas restringidas de la página web, como es la zona de descargas.

Es ahora cuando tenemos que hacer espacio en nuestro disco duro, pues la descarga requiere de varios GB, y más aún en el momento de su descompresión. Otra opción, es cuando solicitamos la cuenta, marcar la opción

de que nos manden un DVD con el contenido de UMLS® y así no tener que descargarlo. El envío suele tardar alrededor de tres semanas en llegar.

Una vez disponemos de todos los archivos necesarios en el disco duro, comenzamos. Lo primero es mover el archivo descargado a la carpeta donde queramos que se instale MetaMap. En nuestro caso, Metamap:

```
> cd ~  
> mkdir metamap  
> mv /"carpeta_descarga"/public_mm_linux_2009v2.tar.bz2  
~/metamap/public_mm_linux_2009v2.tar.bz2
```

El siguiente paso es descomprimir el archivo, vamos al directorio y usamos el siguiente comando de bunzip2:

```
> cd ~/metamap  
> bunzip2 -c public_mm_linux_2009v2.tar.bz2 | tar xvf -
```

Se creará el directorio public_mm dentro del directorio. Entramos en él:

```
> cd public_mm
```

Un paréntesis para un par de configuraciones que nos ayudará a acelerar el proceso. Vamos a declarar la variable de entorno JAVA_HOME en el directorio de instalación de Java. Si no establece la variable el programa le pedirá la información. Para averiguar dónde se encuentra la instalación de Java, utilice el siguiente comando:

```
> which java
```

Obtendremos algo como “/usr/bin/java”. Debemos establecer la variable de entorno JAVA_HOME en el directorio obtenido eliminando “bin/java”, es decir, en nuestro caso en “/usr”:

```
> JAVA_HOME=/usr/  
> export JAVA_HOME
```

Además, añadimos al PATH la dirección “~/metamap/public_mm/bin”:

```
> PATH=~/metamap/public_mm/bin:$PATH  
> export PATH
```

En este momento ya está todo listo para ejecutar el *script* de instalación:

```
> ./bin/install.sh
```

Con una instalación correcta debemos obtener algo similar a:

```
Enter basedir of installation [~/metamap/public_mm]

Basedir is set to ~/metamap/public_mm.

The WSD Server requires Sun's Java Runtime Environment
(JRE)
Sun's Java Developer Kit (JDK) will work as well. if the
command: "which" java returns /usr/local/jre1.4.2/bin/
java, then the
JRE resides in /usr/local/jre1.4.2/.

Where does your distribution of Sun\'s JRE reside?
Enter home path of JRE (JDK) [/usr/bin/java]:

Using /usr/bin/java for JAVA_HOME.

~/metamap/public_mm/WSD_Server/config/disambServer.cfg
generated
~/metamap/public_mm/WSD_Server/config/log4j.properties
generated
Setting up bin directory scripts:
~/metamap/public_mm/bin/SKRrun generated.
~/metamap/public_mm/bin/metamap.TEMPLATE generated.
~/metamap/public_mm/bin/metamap09v2 generated.
~/metamap/public_mm/bin/metamap09v2.tcl generated.
~/metamap/public_mm/bin/mmserver09 generated.
~/metamap/public_mm/bin/skrmedpostctl generated.
~/metamap/public_mm/bin/testapi.sh generated.
~/metamap/public_mm/bin/uninstall.sh generated.
~/metamap/public_mm/bin/wsdserverctl generated.
Setting up test suite:
~/metamap/public_mm/TestSuite/buildTestSuite09.sh
generated.
~/metamap/public_mm/TestSuite/runTest_2009.sh generated.
Checking for required datafiles
Checking for optional datafiles (WSD)
Public MetaMap Install complete.

Public MetaMap Install Settings:

Public MetaMap basedir: ~/metamap/public_mm
Public MetaMap Program Dir: ~/metamap/public_mm/bin
Java Home dir: /usr/bin/java
```

El siguiente paso, es poner en marcha los servidores de soporte para MetaMap. Se ejecutarán en segundo plano:

```
> ./bin/skrmedpostctl start
$Starting skrmedpostctl:
started.
> ./bin/wsdserverctl start
$Starting wsdserverctl:
started.
```

Cuando queramos parar la ejecución de ambos servidores utilizaremos:

```
> ./bin/skrmedpostctl stop
> ./bin/wsdserverctl stop
```

Para comprobar que están en ejecución usamos el comando:

```
> ps -ef | grep java
```

Obtendremos algo así:

```
11318 pts/4 S+ 0:00 grep java
21254 ? S1 0:10 /usr/bin/java -cp ... /MedPost-SKR/
Tagger_server/lib/mps.jar taggerServer
21267 ? S1 0:10 /usr/bin/java -Xmx2g ... WSD_Server/lib/
log4j-1.2.8.jar wsd.server.DisambiguatorServer
```

Y por último, poner en marcha el servidor para poder usar la API de JAVA:

```
> ./bin/mmserver09
```

Como **configuración avanzada**, si tenemos el servidor MetaMap en una máquina distinta a *localhost*, podremos modificar en el fichero “mmserver09” la variable de entorno ACCEPTED_HOST. Por ejemplo:

```
ACCEPTED_HOSTS="[ '127.0.0.1', '192.168.1.17' ]"  
export ACCEPTED_HOSTS
```

Además podemos configurar puertos alternativos. El puerto por defecto es el 8806, para modificarlo modificamos el fichero anterior con los siguientes parámetros:

```
MMSERVER_PORT=8888  
export MMSERVER_PORT
```

Anexo II: Código fuente

El código fuente al completo se puede encontrar en el CD adjunto a la entrega de esta documentación.

Referencias

En este apartado se muestran los distintos artículos referenciados durante la memoria presentada.

[Afantenos et al., 2005] Afantenos, S. D., Karkaletsis, V. y Stamatopoulos P. (2005) Summarization from Medical Documents: A Survey. en Artificial Intelligence in Medicine, 33(2):157- 177.

[Cavnar y Trenkle, 1994] Cavnar, W.B., Trenkle, J.M. (1994). “N-Gram-Based Text Categorization”, en Proceedings of SDAIR-94, 3rd Annual Symposium on Document Analysis and Information Retrieval, pp. 161-175.

[Climent, 2001] Climent S. (2001). Sistemes de resum automàtic de documents / Automatic Text Summarization / Sistemas de resumen automático de documentos. Digit·HVM Revista Digital d’Humanitats. Nº 3. DigitHum 3 Universitat Oberta de Catalunya (UOC). Barcelona ISSN 1575-2275.

- [Cohen et al., 2005]** Cohen, A.M., & Hersh, W.R. (2005). A survey of current work in biomedical text mining. *Briefings in Bioinformatics*, 6(1), 57-71.
- [Ely et al., 2002]** Ely, J.W., Osheroff, J.A., Ebell, M.H., Chambliss, M.L., Vinson, D.C., Stevermer, J.J. y Pifer, E.A. (2002). Obstacles to answering doctors' questions about patient care with evidence: qualitative study. *British Medical Journal*, 324: 710.
- [Hahn y Many, 2000]** Hahn, U., Mani, I. (2000). The Challenges of Automatic Summarization. *Computer*, 33(11):29-36.
- [Humphreys et al., 1998]** Humphreys, B.L., Lindberg, D.A., Schoolman, H.M., y Barnett, G.O. (1998). The Unified Medical Language System: An Informatics Research Collaboration, *Journal of the American Medical Informatics Association*, 5(1), 1-11.
- [Kostoff et al., 2004]** Kostoff R. N., Block J. A., Stump J. A., Pfeil K. M. (2004) "Information content in Medline record fields". *Int J Med Inf* 2004;73(6): 515-27.
- [McCray, 2003]** McCray A.T. (2003). An Upper Level Ontology for the Biomedical Domain. *Comp Funct Genom*. 2003;4:80-4.
- [Paice, 1990]** Paice, C. D. (1990). Constructing Literature Abstracts by Computer: Techniques and Prospects. *Information Processing and Management*, 26(1), pp. 171-186.
- [Reeve et al., 2006]** Reeve, L., Han, H., Nagori, S., Yang, J., Schwimmer, T., Brooks, A. (2006). Concept frequency distribution in biomedical text summarization, *Proceedings of the 15th ACM international conference on*

Information and knowledge management, November 06-11, 2006, Arlington, Virginia, USA.

[Sackett et al., 1996] Sackett D.L., Rosenberg W.M.C., Gray J.A.M., Haynes R.B. and Richardson W.S. (1996). "Evidence-based medicine: what it is and what it isn't". British Medical Journal, 312: 71-72.

[Sparck-Jones, 1999] Sparck-Jones, K. (1999). Automatic Summarizing: Factors and Directions. En I. Mani y M.T. Maybury, Advances in Automatic Text Summarization. The MIT Press.

Bibliografía

En este apartado se presentan los artículos, tesis y trabajos realizados por otros autores y que se han utilizado para la elaboración de esta memoria, sin llegar a ser referenciados en ella.

Carrero, F., Cortizo, J.C., Gómez, J.M., de Buenaga, M. (2008). In the Development of a Spanish Metamap. CIKM'08, October 26–30, 2008, Napa Valley California, USA. Copyright 2008 ACM 978-1-59593-991-3/08/10.

da Cunha, I. (2005). Hacia un modelo lingüístico de resumen automático de artículos médicos en español. Proyecto de Tesis. ISBN: 978-84-89782-37-2.

da Cunha, I., Wanner, L. (2006). Resumen automático de artículos médicos en castellano: integración de técnicas de análisis textual, léxico, discursivo y sintáctico-comunicativo. En VII Congreso de Lingüística General. Barcelona: Publicacions i Edicions de la Universitat de Barcelona. ISBN 84-475-2086-8.

- de la Villa, M. (2008). Una propuesta de generación de resúmenes extractiva basada en conceptos en el ámbito biomédico. Tesina del Máster de Tecnologías Informáticas Avanzadas.
- de la Villa, M., Maña, M. J.. (2009). Estableciendo una línea base para un generador de resúmenes extractivo basado en conceptos en el ámbito biomédico. *Procesamiento del Lenguaje Natural*, Revista no 42, marzo de 2009, pp. 55-62. ISSN 1135-5948.
- de la Villa, M., Maña, M. J.. (2009). Propuesta y evaluación de un método extractivo de generación de resúmenes en el ámbito biomédico basado en conceptos. *Procesamiento del Lenguaje Natural*, núm. 43 (2009), pp. 131-139. ISSN: 1135-5948.
- Fiszman, M., Demner-Fushman, D., Kilicoglu, H., Rindflesch, T. (2008). Automatic summarization of MEDLINE citations for evidence-based medical treatment: A topic-oriented evaluation. doi: 10.1016/j.jbi.2008.10.002.
- Lang, F., Rogers, W., Gay, C. (2010). MetaMap Data File Builder. May 24, 2010.
- Lin, C., Hovy, E. H. (2003). Automatic evaluation of summaries using N-gram co-occurrence statistics. In *Proceedings of 2003 language technology conference (HLT-NAACL 2003)* (Vol. 1(1), pp. 71–78). Edmonton, Canada.
- Maña, M. J. (2003). Generación automática de resúmenes de texto para el acceso a la información. Tesis doctoral, Departamento de Informática, Universidad de Vigo.

- Mateo, P.L., González, J.C., Villena, J. y Martínez, L.L. (2003). Un sistema para resumen automático de textos en castellano. En *Procesamiento de Lenguaje Natural*, 31, pp. 29-36
- Paice, C. y Jones, P. A. (1993). The Identification of Important Concepts in Highly Structured Technical Papers. En *Proceedings of the 16th Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pp. 69-78.
- Plaza, L. (2008). Generación automática de resúmenes con apoyo en ontologías aplicada al dominio biomédico. Tesis del Máster de investigación informática.
- Reeve, L., Han, H., Brooks, A. (2007). The use of domain-specific concepts in biomedical text summarization. doi:10.1016/j.ipm.2007.01.026.
- Rindflesch, T.C., Fiszman, M., Libbus, B. (2005) "Semantic interpretation for the biomedical research literature". Capítulo 14 del libro "Medical Informatics. Knowledge Management and Data Mining in Biomedicine " (Springer's Integrated Series in Information Systems), editores Chen, H., Fuller, S.S., Friedman C., Hersh, W.
- Segura, I., Martínez, P., Samy, D. (2008). Detección de fármacos genéricos en textos biomédicos. *Procesamiento del Lenguaje Natural*, Revista no 40, marzo de 2008, pp. 27-34